AVALIAÇÃO EXPERIMENTAL DO CFIS NA SELEÇÃO DE CARACTERÍSTICAS PARA ÁRVORES DE DECISÃO: DESEMPENHO PREDITIVO, ESTABILIDADE E EFICIÊNCIA COMPUTACIONAL

Diogo Rufino dos Santos[*]
Prof. Esp. Vinicius Godoy Marques[**]

RESUMO

Este estudo avalia o *Combined Feature Importance Score* (CFIS) na seleção de características para árvores de decisão, comparando-o a nove métodos em dez conjuntos de dados. O protocolo emprega dez divisões internas para seleção e análise de estabilidade, seguidas de avaliação externa independente. Foram analisados desempenho preditivo, redução dimensional, estabilidade e eficiência computacional. O CFIS obteve o maior F1 macro médio (0,8217), compartilhou o menor posto médio (4,60) com a Informação Mútua e reduziu a dimensionalidade em 65,77%. Alcançou o segundo maior índice médio de Jaccard (0,7211), com tempo médio de seleção de 0,4580 segundo, 45,18% inferior ao da Informação Mútua. O teste de Friedman não identificou diferenças globais significativas ($p = 0,6155$). Os resultados demonstram competitividade do CFIS nas dimensões avaliadas, sem evidência de superioridade estatística geral.

Palavras-chave: Seleção de características. CFIS. Árvores de decisão. Estabilidade. Eficiência computacional.

ABSTRACT

This study evaluates the Combined Feature Importance Score (CFIS) for feature selection in decision tree classification, comparing it with nine methods across ten datasets. The protocol uses ten internal data splits for selection and stability analysis, followed by independent external evaluation. Predictive performance, dimensionality reduction, stability, and computational efficiency were assessed. CFIS achieved the highest mean macro-F1 (0.8217), tied with Mutual Information for the lowest mean rank (4.60), and reduced dimensionality by 65.77%. It obtained the second-highest mean Jaccard index (0.7211), with a mean selection time of 0.4580 seconds, 45.18% lower than Mutual Information. The Friedman test found no statistically significant overall differences ($p = 0.6155$). Results indicate competitive CFIS performance across the evaluated dimensions, without evidence of overall statistical superiority.

Keywords: *Feature selection. CFIS. Decision trees. Stability. Computational efficiency.*

[*] Discente – Faculdade de Tecnologia de Ourinhos – Fatec Ourinhos – diogo.santos01@aluno.cps.sp.gov.br

[**] Professor Orientador, Especialista – Faculdade de Tecnologia de Ourinhos – Fatec Ourinhos – vinicius.marques@fatecourinhos.edu.br

1 INTRODUÇÃO

A seleção de características, também denominada *feature selection*, constitui uma etapa relevante no desenvolvimento de modelos de aprendizado de máquina, especialmente em aplicações que envolvem conjuntos de dados com elevada dimensionalidade, atributos redundantes ou variáveis pouco informativas. Seu objetivo consiste em identificar subconjuntos de características capazes de preservar informações relevantes para a tarefa preditiva, reduzindo a complexidade dos dados e, potencialmente, os custos associados ao treinamento e à inferência dos modelos (GUYON; ELISSEEFF, 2003). Embora a utilização de um número elevado de características possa ampliar a quantidade de informações disponíveis para o processo de aprendizagem, nem todos os atributos contribuem de maneira equivalente para a capacidade de generalização dos classificadores. Características irrelevantes ou redundantes podem introduzir ruído, aumentar o custo computacional e dificultar a interpretação dos resultados. Dessa forma, a seleção de características representa um problema que envolve não apenas a redução dimensional, mas também o equilíbrio entre desempenho preditivo, estabilidade da seleção e eficiência computacional.

Diferentes estratégias têm sido propostas para enfrentar esse problema. Os métodos baseados em filtros avaliam propriedades estatísticas dos atributos independentemente do treinamento do classificador final, enquanto abordagens do tipo *wrapper* utilizam o desempenho de modelos preditivos para orientar a escolha das características. Por sua vez, métodos incorporados, ou *embedded*, realizam a seleção durante o próprio processo de aprendizagem. Essas categorias apresentam vantagens e limitações relacionadas à qualidade dos subconjuntos selecionados, à dependência em relação ao modelo utilizado e ao custo necessário para executar o procedimento (KOHAVI; JOHN, 1997; GUYON; ELISSEEFF, 2003).Entre as abordagens utilizadas na literatura, destacam-se técnicas fundamentadas em Informação Mútua, regularização L1, importância por permutação, importância de características em modelos baseados em árvores e métodos de explicabilidade, como o *SHapley Additive exPlanations* (SHAP). Embora essas estratégias sejam amplamente empregadas, seus critérios de avaliação diferem, podendo produzir classificações distintas da relevância dos atributos. Consequentemente, a escolha de um método de seleção não deve considerar exclusivamente sua capacidade de melhorar uma métrica preditiva, mas também a consistência dos resultados obtidos em diferentes amostras dos dados.

Nesse contexto, o *Combined Feature Importance Score* (CFIS) foi originalmente proposto por Marques (2024) como uma abordagem híbrida para estimar a importância das características por meio da combinação de diferentes critérios. O método integra informações provenientes da importância por permutação, dos coeficientes de um modelo de regressão logística e da correlação entre os atributos e a variável-alvo. A proposta busca reunir perspectivas complementares de relevância em uma pontuação combinada, permitindo ordenar as características de acordo com sua importância estimada (MARQUES, 2024). Entretanto, a existência de uma pontuação combinada não garante, por si só, superioridade preditiva, maior estabilidade ou menor custo computacional em relação a outros métodos. A avaliação dessas propriedades exige um protocolo experimental que considere diferentes conjuntos de dados, métodos concorrentes, critérios de seleção e procedimentos estatísticos. Particularmente

em modelos baseados em Árvores de Decisão, torna-se relevante investigar se as características priorizadas pelo CFIS contribuem para preservar o desempenho de classificação, reduzir a dimensionalidade e produzir seleções consistentes.

Diante desse cenário, este trabalho apresenta uma avaliação experimental sistemática do CFIS, considerando sua aplicação à seleção de características para classificadores baseados em Árvores de Decisão. O estudo compara o método com nove abordagens alternativas em dez conjuntos de dados de classificação, utilizando um protocolo com múltiplas divisões internas dos dados e avaliação externa independente. São analisados o desempenho preditivo, a redução dimensional, a concordância entre ordenações de importância, a estabilidade dos subconjuntos selecionados e a eficiência computacional.

A questão central que orienta esta pesquisa é: **como o CFIS se comporta em relação a métodos consolidados de seleção de características quanto ao desempenho preditivo, à estabilidade e à eficiência computacional na classificação por Árvores de Decisão?**

O objetivo geral consiste em avaliar comparativamente o comportamento do CFIS em diferentes cenários de classificação, investigando suas vantagens, limitações e relações com métodos tradicionais e técnicas de importância de características. Especificamente, busca-se analisar a capacidade de preservação do desempenho preditivo após a redução dimensional, examinar a consistência das características selecionadas em diferentes divisões dos dados, investigar a concordância entre as ordenações produzidas pelos métodos e comparar os custos computacionais envolvidos no processo de seleção.

A principal contribuição deste estudo não consiste na proposição de uma nova técnica, mas na ampliação das evidências experimentais sobre o método *Combined Feature Importance Score* (CFIS), originalmente apresentado por Marques (2024). Para isso, realiza-se uma avaliação comparativa envolvendo nove abordagens de seleção de características: *Correlation-based Feature Selection* (CFS) (HALL, 1999), regularização L1 (TIBSHIRANI, 1996), *Mean Decrease in Impurity* (MDI) e importância por permutação (PFI) (BREIMAN, 2001), Informação Mútua (COVER; THOMAS, 2006), *Recursive Feature Elimination* (RFE) (GUYON et al., 2002), seleção aleatória de K características (*Random Top-K*), *TreeSHAP* (LUNDBERG et al., 2020) e *Minimum Redundancy Maximum Relevance* (mRMR) (PENG; LONG; DING, 2005). Os experimentos abrangem dez conjuntos de dados de classificação: *20 Newsgroups* (MITCHELL, 1997), *Breast Cancer Wisconsin* (WOLBERG et al., 1993), *Credit Approval* (QUINLAN, 1987), *Gisette* (GUYON et al., 2004), *Iris* (FISHER, 1936), *Pima Indians Diabetes*, *Wine* (AEBERHARD; FORINA, 1992) e três conjuntos sintéticos, denominados *Synthetic 30*, *Synthetic 60* e *Synthetic 120*, cuja geração computacional é fundamentada nas ferramentas apresentadas por Pedregosa et al. (2011).

Esses conjuntos contemplam diferentes dimensionalidades e características dos problemas de classificação, permitindo investigar o comportamento dos métodos em cenários heterogêneos. A investigação adota um protocolo experimental com dez divisões internas dos dados, definição do número de características selecionadas antes da avaliação externa independente e análise multidimensional baseada em

desempenho preditivo, redução de dimensionalidade, concordância entre métodos, estabilidade da seleção e eficiência computacional. Adicionalmente, são empregados testes estatísticos para examinar a significância das diferenças observadas. Dessa maneira, o trabalho busca fornecer evidências sobre as vantagens e limitações do CFIS em relação às abordagens concorrentes, sem pressupor sua superioridade estatística.

2 REFERENCIAL TEÓRICO E TRABALHOS RELACIONADOS

A seleção de características constitui uma etapa importante no desenvolvimento de modelos de aprendizado de máquina, pois busca identificar um subconjunto de atributos relevantes para determinada tarefa preditiva. Em problemas de classificação, essa estratégia pode contribuir para a redução da dimensionalidade, a diminuição da redundância entre variáveis, a simplificação dos modelos e a redução dos custos computacionais. Entretanto, a eliminação de características também pode ocasionar perda de informações relevantes, tornando necessária a avaliação do equilíbrio entre redução dimensional e desempenho preditivo (GUYON; ELISSEEFF, 2003). De acordo com Kohavi e John (1997), os métodos de seleção podem ser organizados em diferentes categorias conforme a estratégia empregada para avaliar os atributos. Os métodos de filtragem, denominados *filter*, utilizam medidas estatísticas ou propriedades dos dados para determinar a relevância das características, geralmente sem depender diretamente do classificador final. Os métodos do tipo *wrapper*, por sua vez, avaliam subconjuntos de características mediante o treinamento de modelos preditivos. Já os métodos incorporados, conhecidos como *embedded*, integram mecanismos de seleção ao próprio processo de aprendizagem.

Essa classificação evidencia que diferentes métodos podem apresentar comportamentos distintos diante de um mesmo conjunto de dados. Enquanto determinadas abordagens priorizam a relação individual entre cada atributo e a variável-alvo, outras consideram interações, redundâncias ou a contribuição das características para as decisões de um modelo específico. Consequentemente, a escolha de uma estratégia de seleção deve considerar não apenas o desempenho de classificação, mas também a estabilidade dos atributos selecionados e o custo necessário para realizar o procedimento.

2.1 Métodos de Seleção de Características

Entre os métodos de filtragem, o *Correlation-based Feature Selection* (CFS), proposto por Hall (1999), utiliza a correlação como critério para identificar subconjuntos de características que apresentem elevada associação com a variável-alvo e baixa redundância entre si. Sua fundamentação considera que um subconjunto adequado deve reunir atributos individualmente relevantes, evitando a inclusão excessiva de informações semelhantes. Outra abordagem fundamentada em propriedades estatísticas é a Informação Mútua, que quantifica a dependência entre variáveis a partir de conceitos da teoria da informação (COVER; THOMAS, 2006). Diferentemente da correlação linear, a Informação Mútua pode identificar determinadas relações não lineares entre características e classes. Entretanto, quando aplicada individualmente

aos atributos, essa medida não elimina necessariamente a redundância existente entre as características mais bem classificadas.

O método *Minimum Redundancy Maximum Relevance* (mRMR), apresentado por Peng, Long e Ding (2005), procura equilibrar essas duas propriedades ao selecionar características que apresentem elevada relevância em relação à variável-alvo e baixa redundância entre si. Dessa maneira, o procedimento considera tanto a capacidade informativa dos atributos quanto a sobreposição de informações presente no subconjunto selecionado.

Entre as técnicas incorporadas, a regularização L1, associada ao método *Least Absolute Shrinkage and Selection Operator* (LASSO), introduz uma penalização proporcional à soma dos valores absolutos dos coeficientes do modelo. Essa propriedade pode conduzir determinados coeficientes a zero, permitindo identificar características que contribuem para a solução ajustada (TIBSHIRANI, 1996). Embora sua aplicação original esteja associada a modelos de regressão, o princípio da regularização L1 também pode ser empregado em classificadores lineares.

A importância baseada na redução de impureza, denominada *Mean Decrease in Impurity* (MDI), utiliza a contribuição das características para a redução dos critérios de impureza durante a construção de modelos baseados em árvores. Essa abordagem está relacionada aos mecanismos de avaliação de atributos empregados em Árvores de Decisão e Florestas Aleatórias (BREIMAN, 2001). Sua principal característica é produzir medidas de importância a partir da estrutura aprendida pelo modelo, embora os resultados possam ser influenciados por propriedades dos atributos e pelo processo de treinamento.

A importância por permutação, ou *Permutation Feature Importance* (PFI), avalia a relevância de uma característica por meio da alteração de seus valores após o treinamento do modelo. O procedimento consiste em permutar os valores de determinado atributo e observar a variação de uma métrica de desempenho. Quanto maior a degradação observada, maior tende a ser a importância atribuída à característica (BREIMAN, 2001). Essa estratégia permite analisar a contribuição dos atributos para um modelo treinado, mas seus resultados podem ser afetados pela presença de características correlacionadas.

O método *Recursive Feature Elimination* (RFE), apresentado no contexto da seleção de genes por Guyon et al. (2002), realiza a eliminação sucessiva de características a partir de critérios de importância estimados por um modelo. Em cada etapa, os atributos considerados menos relevantes são removidos, e o procedimento é repetido até alcançar a quantidade desejada de características. Apesar de sua capacidade de explorar a relação entre seleção e aprendizagem, a necessidade de ajustes sucessivos pode elevar o custo computacional.

No campo da interpretabilidade, o método *SHapley Additive exPlanations* (SHAP) utiliza conceitos da teoria dos jogos para atribuir contribuições às características de um modelo preditivo (LUNDBERG; LEE, 2017). Sua especialização para modelos baseados em árvores, denominada *TreeSHAP*, permite calcular contribuições das características explorando propriedades dessas estruturas (LUNDBERG et al., 2020). Embora tenha sido desenvolvido principalmente para explicação de predições,

o método também pode fornecer ordenações globais de importância por meio da agregação das contribuições individuais.

Por fim, a seleção aleatória de características, denominada neste estudo *Random Top-K*, é utilizada como referência experimental. Nessa abordagem, um subconjunto de tamanho previamente definido é selecionado aleatoriamente, sem considerar medidas de relevância ou o desempenho do classificador. Sua inclusão permite verificar se os métodos avaliados apresentam resultados superiores aos obtidos por uma estratégia que não utiliza informações específicas sobre a importância dos atributos.

2.2 O Método *Combined Feature Importance Score* (CFIS)

O *Combined Feature Importance Score* (CFIS), proposto por Marques (2024), constitui uma abordagem híbrida de avaliação da importância de características, fundamentada na integração de diferentes critérios de relevância. O método combina informações provenientes da importância por permutação (*Permutation Importance*), dos coeficientes de um modelo de regressão logística e da correlação entre as características e a variável-alvo. Seu objetivo consiste em produzir uma pontuação unificada que permita ordenar os atributos segundo diferentes perspectivas de contribuição para o problema de aprendizagem. A utilização de múltiplos critérios parte do pressuposto de que uma única medida de importância pode não representar adequadamente todos os aspectos da relação entre os atributos e a variável-alvo. A importância por permutação procura quantificar a contribuição de uma característica para o desempenho de um modelo preditivo, enquanto os coeficientes da regressão logística representam sua participação na função de decisão de um modelo linear. A correlação, por sua vez, fornece uma medida estatística de associação entre cada atributo e a variável-alvo.

A formulação do CFIS pode ser representada pela Equação 1, na qual as três medidas são normalizadas e combinadas por meio de uma média aritmética:

$$CFIS(f_i) = \frac{1}{3}\left(\frac{PI(f_i)}{\sum_{j=1}^{p} PI(f_j)} + \frac{|CM(f_i)|}{\sum_{j=1}^{p} |CM(f_j)|} + \frac{|Corr(f_i, y)|}{\sum_{j=1}^{p} |Corr(f_j, y)|}\right) \quad (1)$$

Em que:

- f_i representa a i-ésima característica do conjunto de dados;
- p corresponde ao número total de características;
- $PI(f_i)$ representa a importância por permutação da característica f_i;
- $CM(f_i)$ corresponde ao coeficiente associado à característica f_i no modelo de regressão logística;
- $Corr(f_i, y)$ representa a correlação entre a característica f_i e a variável-alvo y.

A normalização busca colocar as diferentes medidas em escalas comparáveis, reduzindo a influência de suas magnitudes originais sobre a pontuação combinada. O fator $\frac{1}{3}$ estabelece pesos iguais para os três componentes, de modo que nenhuma das medidas receba prioridade explícita na formulação. O emprego dos valores absolutos nos componentes associados aos coeficientes e à correlação permite considerar a magnitude das relações identificadas, independentemente de sua direção. Dessa maneira, tanto associações positivas quanto negativas podem contribuir para a pontuação de relevância de uma característica. Após o cálculo das pontuações, os atributos são organizados em ordem decrescente de importância. A seleção pode então ser realizada mediante a retenção das K características mais bem classificadas, conforme o critério estabelecido no protocolo experimental. Assim, o CFIS atua como um mecanismo de ordenação e seleção de atributos, podendo ser empregado antes do treinamento do classificador final.

É importante destacar que o CFIS não foi desenvolvido originalmente neste trabalho. Sua proposição foi apresentada por Marques (2024), enquanto a presente pesquisa concentra-se na avaliação sistemática de seu comportamento diante de métodos concorrentes, considerando desempenho preditivo, redução dimensional, concordância entre ordenações, estabilidade da seleção e eficiência computacional. Os procedimentos específicos de implementação, tratamento dos componentes, definição do número de características selecionadas e configuração dos experimentos serão detalhados na seção de Metodologia, de modo a permitir a reprodução e a análise dos resultados obtidos.

2.3 **Avaliação de Métodos de Seleção de Características**

A avaliação de métodos de seleção de características não deve se restringir ao desempenho preditivo obtido após a redução dimensional. Embora métricas de classificação permitam verificar a capacidade de generalização dos modelos, elas não descrevem isoladamente a consistência dos subconjuntos selecionados ou os recursos computacionais necessários para obtê-los.

Uma dimensão relevante é a redução de dimensionalidade, expressa pela proporção de características removidas em relação ao conjunto original. Essa medida permite quantificar a simplificação dos dados, mas deve ser interpretada em conjunto com o desempenho preditivo, pois uma redução elevada pode ocasionar a eliminação de atributos informativos. Outra dimensão é a estabilidade da seleção, relacionada à consistência dos subconjuntos obtidos quando o método é aplicado a diferentes amostras de um mesmo conjunto de dados. Um procedimento estável tende a selecionar características semelhantes diante de pequenas alterações nas observações utilizadas, enquanto métodos instáveis podem produzir subconjuntos significativamente diferentes.

A estabilidade pode ser investigada por meio do índice de Jaccard, que quantifica a sobreposição entre dois conjuntos de características. Também podem ser empregadas medidas específicas de estabilidade que consideram a concordância esperada ao acaso, como a proposta por Nogueira, Sechidis e Brown (2018). Essas medidas fornecem informações complementares ao desempenho preditivo, permitindo examinar a reprodutibilidade das escolhas realizadas pelos algoritmos.

A concordância entre métodos representa outra perspectiva de análise. Diferentemente da estabilidade, que examina a consistência de um mesmo procedimento em diferentes amostras, a concordância investiga a semelhança entre as ordenações de importância produzidas por abordagens distintas. Para essa finalidade, podem ser utilizadas medidas de correlação entre posições, como os coeficientes de Spearman e Kendall, além de indicadores de sobreposição entre os subconjuntos selecionados.

A eficiência computacional também constitui um critério relevante, especialmente quando os métodos apresentam custos distintos de ajuste, avaliação e ordenação das características. Procedimentos que dependem de múltiplos treinamentos ou avaliações repetidas podem apresentar maior custo do que abordagens baseadas em medidas estatísticas diretas. Assim, a comparação dos tempos de seleção e processamento permite analisar possíveis relações entre qualidade preditiva e custo computacional.

Por fim, a comparação de múltiplos métodos em diferentes conjuntos de dados exige cautela na interpretação das diferenças observadas. Demšar (2006) discute procedimentos estatísticos apropriados para comparações entre algoritmos em múltiplas bases de dados, incluindo testes não paramétricos baseados em postos. Esses procedimentos contribuem para distinguir diferenças descritivas de resultados sustentados por evidência estatística.

2.4 Síntese dos Trabalhos Relacionados e Lacunas de Pesquisa

Os estudos sobre seleção de características apresentam diferentes perspectivas para a identificação de atributos relevantes. Enquanto Hall (1999) e Peng, Long e Ding (2005) investigam estratégias fundamentadas na relevância e na redundância entre características, Guyon et al. (2002) explora a seleção orientada por modelos preditivos. Por sua vez, Lundberg et al. (2020) apresenta uma abordagem de explicabilidade para modelos baseados em árvores, cujas contribuições podem ser agregadas para produzir medidas globais de importância. Essas pesquisas demonstram a diversidade de critérios disponíveis, mas não estabelecem que uma única estratégia seja necessariamente a mais adequada para diferentes conjuntos de dados e objetivos de avaliação. Nesse contexto, Marques (2024) propõe o *Combined Feature Importance Score* (CFIS), combinando medidas estatísticas e informações provenientes de modelos preditivos para estimar a relevância das características. Entretanto, a formulação de uma medida combinada não demonstra, isoladamente, sua capacidade de preservar o desempenho preditivo, produzir seleções estáveis ou apresentar eficiência computacional competitiva. Essas propriedades precisam ser investigadas empiricamente, especialmente quando o método é comparado a abordagens que utilizam critérios distintos de importância.

Diante disso, a presente pesquisa concentra-se na avaliação comparativa do CFIS sob diferentes perspectivas, considerando não apenas a qualidade preditiva dos subconjuntos selecionados, mas também sua estabilidade, a concordância entre métodos, a redução dimensional e os custos computacionais. A contribuição do estudo está na análise conjunta dessas propriedades em um protocolo experimental comum, permitindo identificar vantagens, limitações e possíveis relações de compromisso entre os critérios avaliados.

3 METODOLOGIA

Esta pesquisa caracteriza-se como aplicada, quantitativa e experimental, com o objetivo de avaliar comparativamente o método *Combined Feature Importance Score* (CFIS) em problemas de classificação supervisionada. O estudo contempla dez conjuntos de dados, nove métodos concorrentes de seleção de características e uma condição de referência sem seleção, denominada *All Features*. Todos os subconjuntos são avaliados por meio de um classificador de Árvore de Decisão, considerando desempenho preditivo, redução dimensional, estabilidade, concordância entre métodos e eficiência computacional.

O protocolo distingue uma etapa interna, destinada à seleção de características e à definição das configurações experimentais, de uma avaliação externa, reservada à mensuração do desempenho preditivo. São realizadas dez divisões internas por conjunto de dados, utilizadas também nas análises de estabilidade. A comparação dos resultados emprega estatísticas descritivas e testes inferenciais, buscando identificar as vantagens e limitações do CFIS em relação às abordagens concorrentes.

3.1 Conjuntos de Dados

Foram utilizados dez conjuntos de dados de classificação supervisionada, selecionados por apresentarem diferentes dimensionalidades, quantidades de observações e estruturas de classes. Sete são públicos: *20 Newsgroups*, *Breast Cancer Wisconsin*, *Credit Approval*, *Gisette*, *Iris*, *Pima Indians Diabetes* e *Wine*. Os demais são sintéticos, denominados *Synthetic 30*, *Synthetic 60* e *Synthetic 120*. A Tabela 1 apresenta suas referências.

Tabela 1 – Conjuntos de dados utilizados na avaliação experimental

Conjunto de dados	**Tipo**	**Referência**
20 Newsgroups	Público	(MITCHELL, 1997)
Breast Cancer	Público	(WOLBERG et al., 1993)
Credit Approval	Público	(QUINLAN, 1987)
Gisette	Público	(GUYON et al., 2004)
Iris	Público	(FISHER, 1936)
Pima Diabetes	Público	(SMITH et al., 1988)
Wine	Público	(AEBERHARD; FORINA, 1992)
Synthetic 30	Sintético	(PEDREGOSA et al., 2011)
Synthetic 60	Sintético	(PEDREGOSA et al., 2011)
Synthetic 120	Sintético	(PEDREGOSA et al., 2011)

Os conjuntos sintéticos permitem investigar o comportamento dos métodos sob diferentes quantidades de atributos. Sua reprodução depende dos parâmetros de geração, incluindo características informativas e redundantes, distribuição das classes e sementes aleatórias. O escopo deste artigo foi delimitado aos dez problemas de classificação após uma investigação experimental mais ampla, que também contemplava regressão.

3.2 **Métodos Comparativos e Configurações**

O CFIS foi comparado com nove métodos que representam diferentes estratégias de seleção, incluindo correlação, regularização, informação mútua, importância estimada por modelos, eliminação recursiva, explicabilidade e seleção aleatória. A Tabela 2 sintetiza seus fundamentos e critérios de seleção.

Tabela 2 – Métodos de seleção de características comparados

Método	**Fundamento**	**Critério de seleção**
CFIS	Combinação de medidas	Pontuação composta de importância
CFS	Correlação	Relevância e redundância
L1	Regularização	Magnitude dos coeficientes
MDI	Modelos baseados em árvores	Redução de impureza
Informação Mútua	Teoria da informação	Dependência com a variável-alvo
PFI	Permutação	Variação do desempenho preditivo
RFE	Eliminação recursiva	Importância estimada pelo modelo
Random Top-K	Seleção aleatória	Subconjunto aleatório de tamanho K
TreeSHAP	Explicabilidade	Contribuições atribuídas às características
mRMR	Informação Mútua	Máxima relevância e mínima redundância

O número de características selecionadas (K) foi definido individualmente para cada combinação entre método e conjunto de dados durante a validação interna, sendo posteriormente mantido fixo na avaliação externa. Foram preservadas a formulação original do CFIS e as configurações registradas dos procedimentos experimentais.

3.3 **Protocolo Experimental**

Inicialmente, os dados foram organizados em conjuntos destinados à validação interna e à avaliação externa. Na etapa interna, dez divisões foram utilizadas para produzir ordenações de importância, selecionar subconjuntos de características e definir K para cada combinação entre método e conjunto de dados. Como essa definição ocorreu individualmente, métodos distintos puderam selecionar quantidades diferentes de atributos em uma mesma base. Os valores escolhidos permaneceram fixos na avaliação externa, sem ajustes baseados nos dados de teste.

Na etapa externa, os classificadores foram treinados com os atributos selecionados e avaliados em dados não utilizados na definição das configurações. Também foi considerada a condição *All Features*, que utiliza todos os atributos disponíveis. O protocolo compreendeu 100 combinações entre dez métodos e dez conjuntos de dados, acrescidas de dez avaliações de referência, totalizando 110 avaliações externas. A Figura 1 apresenta as etapas do procedimento.

As dez divisões internas também subsidiaram as análises de estabilidade, concordância e eficiência computacional. Na avaliação externa, cada método utilizou seu próprio K, enquanto as análises complementares de estabilidade contemplaram comparações com quantidades comuns de características quando disponíveis. Essa distinção é relevante porque o tamanho dos subconjuntos pode influenciar tanto o desempenho preditivo quanto as medidas de estabilidade.

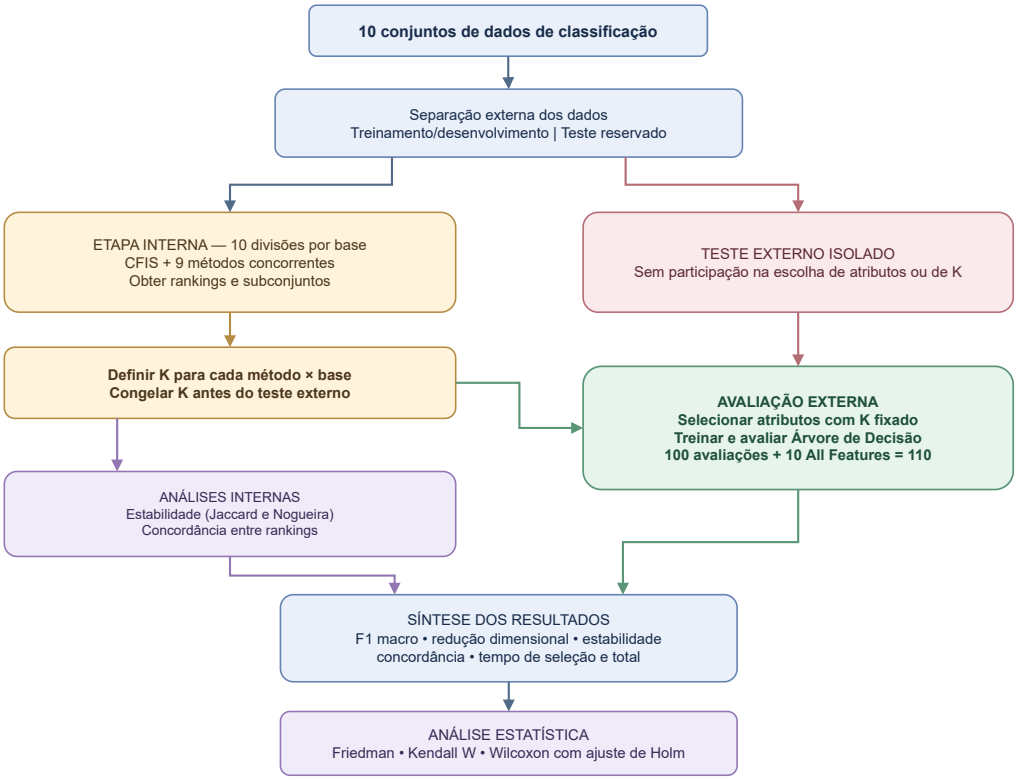


Figura 1 – Fluxograma do protocolo experimental de avaliação do CFIS

Fonte: elaborado pelos autores.

3.4 Métricas de Avaliação

Foram consideradas métricas de desempenho preditivo, redução dimensional, posicionamento relativo, estabilidade, concordância entre métodos e eficiência computacional.

3.4.1 Desempenho Preditivo

O desempenho foi avaliado pelo F1 macro, que atribui o mesmo peso a cada classe, independentemente de sua frequência. Para uma classe c, a precisão (P_c) e a revocação (R_c) são definidas por:

$$P_c = \frac{VP_c}{VP_c + FP_c} \tag{2}$$

$$R_c = \frac{VP_c}{VP_c + FN_c} \tag{3}$$

Em que VP_c, FP_c e FN_c representam verdadeiros positivos, falsos positivos e falsos negativos, respectivamente. O F1 de cada classe corresponde à média

harmônica entre precisão e revocação, enquanto o F1 macro representa a média aritmética dos valores obtidos nas C classes:

$$F1_c = 2 \cdot \frac{P_c R_c}{P_c + R_c} \tag{4}$$

$$F1_{\text{macro}} = \frac{1}{C} \sum_{c=1}^{C} F1_c \tag{5}$$

3.4.2 **Redução Dimensional**

A redução dimensional corresponde ao percentual de características removidas pelo método de seleção:

$$R_{\text{dim}} = \left(1 - \frac{K}{p}\right) \times 100 \tag{6}$$

Em que K representa a quantidade de características selecionadas e p o total de atributos originalmente disponíveis. Valores maiores indicam maior redução.

3.4.3 **Posto Médio**

O posto médio representa o posicionamento relativo dos métodos nos conjuntos de dados avaliados. Em cada conjunto, os métodos são ordenados pelo F1 macro, atribuindo-se o posto 1 ao melhor desempenho e, em caso de empate, a média das posições correspondentes. O posto médio é definido por:

$$\overline{r}_m = \frac{1}{D} \sum_{d=1}^{D} r_{m,d} \tag{7}$$

Em que $\overline{r}_m$ representa o posto médio do método m, D o número de conjuntos de dados e $r_{m,d}$ a posição do método m no conjunto d. Valores menores indicam melhor posicionamento relativo.

3.4.4 **Estabilidade da Seleção**

A estabilidade foi avaliada pelos índices de Jaccard e Nogueira. O índice de Jaccard mede a sobreposição entre dois subconjuntos de características A e B:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{8}$$

Para cada combinação entre método e conjunto de dados, foram comparados todos os pares das dez seleções internas, totalizando 45 comparações:

$$N_{\text{pares}} = \binom{10}{2} = 45 \tag{9}$$

Considerando dez métodos e dez conjuntos de dados, foram realizadas 4.500 comparações pareadas. Valores de Jaccard próximos de 1 indicam maior sobreposição entre os subconjuntos.

Complementarmente, utilizou-se a medida de estabilidade de Nogueira, Sechidis e Brown (2018), que considera a concordância esperada ao acaso. Para M execuções e p características, seu estimador é representado por:

$$\widehat{\Phi} = 1 - \frac{\frac{1}{p}\sum_{j=1}^{p} s_j^2}{\frac{\overline{k}}{p}\left(1 - \frac{\overline{k}}{p}\right)} \tag{10}$$

Em que s_j^2 representa a variância amostral do indicador de seleção da característica j entre as execuções, e $\overline{k}$ corresponde à quantidade média de características selecionadas. A medida exige um universo comum de características entre as seleções comparadas. Como essa condição não foi atendida em três conjuntos de dados, os resultados de Nogueira foram considerados válidos em sete bases, sem imputação dos valores inválidos.

3.4.5 Concordância entre Métodos

A concordância entre as ordenações de importância foi analisada pelos coeficientes de Spearman e Kendall. Na ausência de empates, suas formulações são:

$$\rho = 1 - \frac{6\sum_{i=1}^{p} d_i^2}{p(p^2-1)} \tag{11}$$

$$\tau = \frac{N_c - N_d}{\binom{p}{2}} \tag{12}$$

Em que d_i representa a diferença entre as posições atribuídas à característica i, enquanto N_c e N_d correspondem às quantidades de pares concordantes e discordantes. Essas medidas permitem comparar as ordenações produzidas pelo CFIS e pelos métodos concorrentes, independentemente do desempenho preditivo.

3.4.6 Eficiência Computacional

A eficiência foi avaliada pelo tempo de seleção de características e pelo tempo total registrado no procedimento experimental, expresso por:

$$T_{\text{total}} = T_{\text{selecao}} + T_{\text{demais}} \tag{13}$$

Em que T_{selecao} corresponde ao custo da seleção e T_{demais} às demais etapas cronometradas. Os tempos foram registrados em segundos e analisados em conjunto com o desempenho preditivo e a redução dimensional.

3.5 Procedimentos Estatísticos

A comparação estatística considerou os resultados dos métodos nos dez conjuntos de dados de classificação. Além das médias e dos postos médios, foi empregado o teste não paramétrico de Friedman para investigar diferenças globais de desempenho entre os métodos (DEMŠAR, 2006). Sua estatística é definida por:

$$\chi_F^2 = \frac{12N}{k(k+1)} \left[\sum_{j=1}^{k} \overline{R}_j^2 - \frac{k(k+1)^2}{4} \right] \tag{14}$$

Em que N representa o número de conjuntos de dados, k o número de métodos e $\overline{R}_j$ o posto médio do método j. Complementarmente, calculou-se o coeficiente W de Kendall para quantificar a concordância entre as classificações:

$$W = \frac{\chi_F^2}{N(k-1)} \tag{15}$$

Também foram realizadas comparações pareadas pelo teste de Wilcoxon, com correção de Holm para múltiplas comparações (HOLM, 1979). Os resultados inferenciais foram interpretados juntamente com as diferenças descritivas, distinguindo desempenho observado de evidência de superioridade estatística.

4 RESULTADOS

Esta seção apresenta os resultados da avaliação experimental do método *Combined Feature Importance Score* (CFIS) em comparação com nove abordagens de seleção de características, considerando dez conjuntos de dados de classificação. A análise contempla o desempenho preditivo dos classificadores, a redução dimensional, a eficiência computacional, a estabilidade dos subconjuntos selecionados, a concordância entre métodos e os resultados dos testes estatísticos. Os valores apresentados correspondem às avaliações externas registradas no protocolo experimental, enquanto as medidas de estabilidade foram calculadas a partir das seleções obtidas nas dez divisões internas de cada conjunto de dados. Essa distinção permite analisar separadamente a capacidade preditiva dos subconjuntos e a consistência dos procedimentos de seleção.

4.1 Desempenho Preditivo

A Tabela 3 apresenta o desempenho médio dos dez métodos de seleção de características, considerando o F1 macro, a posição média no desempenho preditivo, a redução dimensional e os tempos computacionais registrados.

O CFIS apresentou o maior F1 macro médio entre os métodos avaliados, com valor de 0,8217, seguido pela Informação Mútua, com 0,8200, e pelo RFE, com 0,8180. A diferença absoluta entre o CFIS e a Informação Mútua foi de aproximadamente 0,0017, indicando resultados preditivos próximos quando considerados os valores médios das dez bases. Em relação às posições médias, CFIS e Informação Mútua

Tabela 3 – Resultados médios dos métodos de seleção de características

Método	**F1 macro**	**Posto**	**Red. (%)**	**Seleção (s)**	**Total (s)**
CFIS	0,8217	4,60	65,77	0,4580	0,4750
Informação Mútua	0,8200	4,60	58,31	0,8355	0,8562
CFS	0,8091	4,75	57,65	0,0715	0,0938
RFE	0,8180	5,05	61,95	7,6364	7,6535
PFI	0,8141	5,35	53,26	1,8938	1,9129
MDI	0,8130	5,40	55,20	0,0550	0,0828
L1	0,8123	5,45	76,82	0,0243	0,0322
TreeSHAP	0,8145	6,15	62,49	0,2797	0,3019
Random Top-K	0,7998	6,80	31,25	0,0002	0,0368
mRMR	0,7988	6,85	58,57	22,3226	22,3374

apresentaram o mesmo valor, de 4,60. O CFS ocupou a posição seguinte, com posto médio de 4,75. Esses resultados indicam que a ordenação dos métodos pelo F1 macro médio não coincide necessariamente com a ordenação por postos, uma vez que os dois critérios resumem os resultados de maneiras diferentes. A seleção aleatória apresentou F1 macro médio de 0,7998, enquanto o mRMR registrou 0,7988. Entretanto, essas diferenças descritivas não devem ser interpretadas isoladamente como evidência de superioridade estatística dos métodos mais bem posicionados.

4.2 **Eficiência Computacional**

A eficiência computacional foi analisada a partir dos tempos médios de seleção de características e de execução total dos procedimentos experimentais. Conforme apresentado na Tabela 3, o CFIS registrou tempo médio de seleção de 0,4580 segundo e tempo total médio de 0,4750 segundo, posicionando-se como o sexto método mais rápido entre os dez avaliados. Embora abordagens como L1, MDI, CFS e *TreeSHAP* tenham apresentado menores custos computacionais, o CFIS demonstrou vantagens expressivas em relação a métodos de maior complexidade de processamento.

A Tabela 4 apresenta os fatores de aceleração obtidos pelo CFIS em comparação com os métodos que registraram maiores tempos médios de seleção. O CFIS foi aproximadamente 1,82 vez mais rápido que a Informação Mútua, 4,13 vezes mais rápido que o PFI, 16,67 vezes mais rápido que o RFE e 48,74 vezes mais rápido que o mRMR. Essas diferenças correspondem a reduções relativas de tempo de 45,18%, 75,82%, 94,00% e 97,95%, respectivamente. Os fatores apresentados foram calculados pela razão entre os tempos médios de seleção, não representando médias de acelerações individuais por conjunto de dados.

Destaca-se a comparação com a Informação Mútua, que apresentou desempenho preditivo médio próximo ao CFIS (0,8200 contra 0,8217) e compartilhou o mesmo posto médio (4,60). Apesar dessa proximidade, o CFIS alcançou maior redução dimensional (65,77% contra 58,31%) e menor tempo de seleção, evidenciando uma relação favorável entre desempenho preditivo, compactação dos atributos e custo

Tabela 4 – Ganho de eficiência computacional do CFIS em relação aos métodos com maior tempo médio de seleção

Método	**Tempo (s)**	**Speedup**	**Redução (%)**
Informação Mútua	0,8355	1,82×	45,18
PFI	1,8938	4,13×	75,82
RFE	7,6364	16,67×	94,00
mRMR	22,3226	48,74×	97,95
CFIS (referência)	0,4580	1,00×	0,00

computacional. Esses resultados demonstram que, embora não seja a abordagem de menor latência, o CFIS oferece vantagens computacionais relevantes frente a determinados métodos concorrentes, preservando desempenho preditivo competitivo.

4.3 Redução Dimensional

A redução dimensional representa a proporção média de características removidas pelos métodos de seleção. Conforme apresentado na Tabela 3, o CFIS registrou redução média de 65,77%, preservando aproximadamente 34,23% das características disponíveis nos conjuntos de dados avaliados. Entre os métodos comparados, a regularização L1 apresentou a maior redução média, de 76,82%, seguida pelo CFIS, com 65,77%, e pelo *TreeSHAP*, com 62,49%. O RFE apresentou redução de 61,95%, enquanto a Informação Mútua registrou 58,31%. A seleção aleatória apresentou a menor redução média, de 31,25%. Esse resultado evidencia que os procedimentos avaliados produziram diferentes níveis de retenção de características nos registros externos, apesar da utilização de critérios de seleção definidos no protocolo experimental. A interpretação da redução dimensional deve considerar sua relação com o desempenho preditivo. Uma redução mais elevada não representa necessariamente um resultado superior, especialmente quando acompanhada por perda de capacidade de classificação. Nesse sentido, os resultados do CFIS indicam uma combinação descritivamente favorável entre F1 macro médio e proporção de características removidas, embora essa observação não estabeleça superioridade estatística.

4.4 Estabilidade dos Subconjuntos Selecionados

A estabilidade foi avaliada por meio da comparação dos subconjuntos de características obtidos nas dez divisões internas de cada conjunto de dados. Para cada combinação entre método e conjunto de dados, foram realizadas 45 comparações entre pares de seleções, totalizando 4.500 comparações no experimento. A Tabela 5 apresenta os valores médios do índice de Jaccard, seus respectivos desvios-padrão entre os conjuntos de dados e os resultados válidos da medida de estabilidade de Nogueira. O CFS apresentou o maior índice médio de Jaccard (0,7365), seguido pelo CFIS (0,7211) e pela regularização L1 (0,7125), enquanto o método *Random Top-K* registrou o menor valor (0,3426). Esses resultados indicam diferenças na consistência dos subconjuntos selecionados ao longo das divisões internas, com maior sobreposição média para CFS, CFIS e L1.

Tabela 5 – Ranking de estabilidade dos métodos de seleção de características pelo índice de Nogueira

Método	**Nogueira**	**Jaccard**
CFIS	0,7049	0,7211
Informação Mútua	0,7048	0,6501
CFS	0,6900	0,7365
L1	0,6451	0,7125
RFE	0,6172	0,6799
mRMR	0,5877	0,5888
TreeSHAP	0,5075	0,6539
MDI	0,4889	0,6402
PFI	0,4603	0,6217
Random Top-K	-0,0151	0,3426

Na medida de Nogueira, o CFIS apresentou valor médio de 0,7049, próximo ao registrado pela Informação Mútua (0,7048), enquanto o CFS obteve 0,6900 e o método *Random Top-K* apresentou -0,0151. Entretanto, essa medida foi considerada válida em apenas sete dos dez conjuntos de dados, pois *20 Newsgroups*, *Credit Approval* e *Gisette* apresentaram inconsistências no universo de características entre as seleções registradas. Dessa forma, os resultados de Nogueira correspondem exclusivamente às bases válidas, enquanto os valores de Jaccard representam os dez conjuntos avaliados. Além disso, como os valores de K foram definidos individualmente para cada método, as comparações de estabilidade devem ser interpretadas considerando possíveis diferenças na quantidade de características selecionadas.

4.5 **Concordância entre Métodos**

A concordância entre os métodos foi investigada por meio da comparação das ordenações de importância atribuídas às características, utilizando o coeficiente de correlação de Spearman. Os resultados indicaram correlação média de 0,6111 entre o CFIS e o CFS, de 0,5339 entre o CFIS e a regularização L1 e de 0,4820 entre o CFIS e a Informação Mútua. Entre essas comparações, a maior associação foi observada com o CFS, enquanto a Informação Mútua apresentou a menor correlação média. Esses resultados evidenciam diferentes níveis de concordância entre as ordenações produzidas pelos métodos, indicando que, embora compartilhem determinadas informações sobre a relevância das características, suas classificações não são equivalentes. Essa concordância parcial é compatível com a utilização de diferentes critérios de avaliação de importância, não sendo possível, entretanto, determinar apenas pelos coeficientes quais componentes explicam as divergências observadas.

5 **CONCLUSÃO**

Este trabalho apresentou uma avaliação experimental do método *Combined Feature Importance Score* (CFIS) em problemas de classificação supervisionada,

considerando dez conjuntos de dados e nove abordagens concorrentes de seleção de características. A investigação contemplou desempenho preditivo, redução dimensional, estabilidade dos subconjuntos selecionados, concordância entre métodos e eficiência computacional. Os resultados indicaram que o CFIS constitui uma alternativa competitiva, caracterizada pela combinação de propriedades relevantes para a seleção de características, em vez da otimização isolada de um único critério.

O CFIS alcançou o maior F1 macro médio entre os métodos avaliados (0,8217) e compartilhou o menor posto médio (4,60) com a Informação Mútua. Na análise de estabilidade, apresentou o maior índice médio de Nogueira (0,7049), considerando os sete conjuntos de dados válidos, e o segundo maior índice médio de Jaccard (0,7211), calculado sobre as dez bases. Adicionalmente, obteve redução dimensional média de 65,77%, preservando aproximadamente um terço das características originais. Esses resultados evidenciam um comportamento descritivamente favorável na combinação entre desempenho preditivo, estabilidade e redução dimensional.

Em relação à eficiência computacional, o CFIS registrou tempo médio de seleção de 0,4580 segundo, apresentando acelerações de aproximadamente 1,82 vez em relação à Informação Mútua, 4,13 vezes em relação ao PFI, 16,67 vezes em relação ao RFE e 48,74 vezes em relação ao mRMR. Destaca-se a comparação com a Informação Mútua, que apresentou desempenho preditivo médio próximo ao CFIS (0,8200 contra 0,8217) e compartilhou o mesmo posto médio, mas registrou maior tempo de seleção e menor redução dimensional. Nessa comparação, o CFIS reduziu o tempo médio de seleção em aproximadamente 45,18%, mantendo desempenho preditivo semelhante. Embora não tenha sido o método mais rápido entre os avaliados, esses resultados demonstram vantagens computacionais relevantes em relação a determinadas abordagens concorrentes.

A interpretação desses resultados deve considerar que as diferenças descritivas observadas não se traduziram em superioridade estatística demonstrada. O teste de Friedman não identificou diferenças globais significativas entre os métodos ($p = 0,6155$), resultado também observado nas comparações pareadas com correção de Holm. Em relação à condição *All Features*, o CFIS apresentou desempenho preditivo superior em quatro conjuntos de dados, equivalente em um e inferior em cinco, indicando que os benefícios da seleção dependem das características do problema. Dessa forma, os resultados sustentam a competitividade do CFIS no cenário investigado, mas não permitem afirmar sua superioridade geral sobre os métodos comparados.

Entre as limitações, destacam-se a utilização de um único classificador final, a realização de uma avaliação externa por combinação entre método e conjunto de dados e a disponibilidade do índice de Nogueira em apenas sete bases. Trabalhos futuros poderão ampliar a investigação para diferentes classificadores, incorporar avaliações externas repetidas e examinar a sensibilidade do CFIS a diferentes configurações, dimensionalidades e características dos dados. Em síntese, este estudo contribui com evidências experimentais de que o CFIS apresenta uma relação favorável entre desempenho preditivo, estabilidade, redução dimensional e custo de seleção, constituindo uma alternativa promissora para investigações mais abrangentes em seleção de características.

AEBERHARD, S.; FORINA, M. *Wine*. 1992. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/dataset/109/wine>. Citado 2 vezes nas páginas 3 e 9.

BREIMAN, L. Random forests. *Machine Learning*, v. 45, p. 5–32, 2001. Citado 2 vezes nas páginas 3 e 5.

COVER, T. M.; THOMAS, J. A. *Elements of Information Theory*. 2. ed. Hoboken: John Wiley and Sons, 2006. ISBN 9780471241959. Citado 2 vezes nas páginas 3 e 4.

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006. Disponível em: <https://www.jmlr.org/papers/v7/demsar06a.html>. Citado 2 vezes nas páginas 8 e 14.

FISHER, R. A. *Iris*. 1936. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/dataset/53/iris>. Citado 2 vezes nas páginas 3 e 9.

GUYON, I.; ELISSEEFF, A. An introduction to variable and feature selection. *Journal of Machine Learning Research*, v. 3, p. 1157–1182, 2003. Disponível em: <https://www.jmlr.org/papers/v3/guyon03a.html>. Citado 2 vezes nas páginas 2 e 4.

GUYON, I. et al. *Gisette*. 2004. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/dataset/170/gisette>. Citado 2 vezes nas páginas 3 e 9.

GUYON, I. et al. Gene selection for cancer classification using support vector machines. *Machine Learning*, v. 46, p. 389–422, 2002. Citado 3 vezes nas páginas 3, 5 e 8.

HALL, M. A. *Correlation-based Feature Selection for Machine Learning*. Tese (Doutorado) — The University of Waikato, Hamilton, New Zealand, 1999. Disponível em: <https://hdl.handle.net/10289/15043>. Citado 3 vezes nas páginas 3, 4 e 8.

HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979. Citado na página 14.

KOHAVI, R.; JOHN, G. H. Wrappers for feature subset selection. *Artificial Intelligence*, v. 97, n. 1–2, p. 273–324, 1997. Citado 2 vezes nas páginas 2 e 4.

LUNDBERG, S. M. et al. From local explanations to global understanding with explainable ai for trees. *Nature Machine Intelligence*, v. 2, p. 56–67, 2020. Citado 3 vezes nas páginas 3, 5 e 8.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems*. [s.n.], 2017. v. 30. Disponível em: <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>. Citado na página 5.

MARQUES, V. G. A métrica cfis: Uma nova perspectiva na análise da importância das features em modelos de machine learning. *Revista e-Fatec*, v. 14, n. 2, oct 2024. Citado 5 vezes nas páginas 2, 3, 6, 7 e 8.

MITCHELL, T. *Twenty Newsgroups*. 1997. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/dataset/113/twenty+newsgroups>. Citado 2 vezes nas páginas 3 e 9.

NOGUEIRA, S.; SECHIDIS, K.; BROWN, G. On the stability of feature selection algorithms. *Journal of Machine Learning Research*, v. 18, n. 174, p. 1–54, 2018. Disponível em: <https://www.jmlr.org/papers/v18/17-514.html>. Citado 2 vezes nas páginas 7 e 13.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Disponível em: <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Citado 2 vezes nas páginas 3 e 9.

PENG, H.; LONG, F.; DING, C. Feature selection based on mutual information: Criteria of max-dependency, max-relevance, and min-redundancy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 27, n. 8, p. 1226–1238, 2005. Citado 3 vezes nas páginas 3, 5 e 8.

QUINLAN, J. R. *Credit Approval*. 1987. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/dataset/27/credit+approval>. Citado 2 vezes nas páginas 3 e 9.

SMITH, J. W. et al. Using the adap learning algorithm to forecast the onset of diabetes mellitus. In: *Proceedings of the Annual Symposium on Computer Application in Medical Care*. [S.l.: s.n.], 1988. p. 261–265. Citado na página 9.

TIBSHIRANI, R. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, v. 58, n. 1, p. 267–288, 1996. Citado 2 vezes nas páginas 3 e 5.

WOLBERG, W. et al. *Breast Cancer Wisconsin (Diagnostic)*. 1993. UCI Machine Learning Repository. Disponível em: <https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>. Citado 2 vezes nas páginas 3 e 9.