Avaliação Comparativa do CFIS na Seleção de Atributos para Detecção de Websites Phishing: Desempenho, Estabilidade e Eficiência Computacional

Henrique Simões Gratão[*]
João Carlos Variani[*]
Yan Rocha[*]
Prof. Esp. Vinicius Godoy Marques[**]

Resumo

A seleção de atributos pode reduzir a dimensionalidade de problemas de classificação, mas diferentes critérios de relevância podem produzir subconjuntos com desempenho, estabilidade e custo computacional distintos. Este artigo investiga o método *Combined Feature Importance Score* (CFIS) na detecção de websites *phishing*, comparando-o a L1, informação mútua, *Correlation-based Feature Selection* (CFS), ReliefF, TreeSHAP, importância por permutação (PFI), seleção aleatória e ao uso integral dos atributos. O conjunto experimental contém 11.430 registros e 87 atributos. Após a separação estratificada de 70% para desenvolvimento e 30% para teste externo, realizou-se validação cruzada estratificada de cinco partições sobre os 8.001 registros de desenvolvimento, utilizando Árvore de Decisão, Regressão Logística e Random Forest. Foram analisados desempenho preditivo, tempo de seleção, estabilidade entre partições, concordância de subconjuntos e testes não paramétricos. No conjunto externo de 3.429 registros, o CFIS alcançou F1-macro de 0,9355, 0,9425 e 0,9630, respectivamente, selecionando 15, 60 e 45 dos 87 atributos. Na Regressão Logística, obteve o maior F1-macro entre os métodos avaliados. O tempo médio de seleção do CFIS foi inferior ao de TreeSHAP, PFI e ReliefF, mas superior ao de L1 e CFS. Os testes pareados com correção de Holm não identificaram superioridade estatisticamente significativa do CFIS. Conclui-se que o método constitui uma alternativa competitiva para seleção de atributos no cenário investigado, com estabilidade elevada e custo computacional moderado.

Palavras-chave: Phishing. Seleção de Atributos. CFIS. Aprendizado de Máquina. Estabilidade. Eficiência Computacional.

[*] Discentes – Curso Superior de Tecnologia em Ciência de Dados – Faculdade de Tecnologia de Ourinhos – Fatec Ourinhos – {henrique.gratao, joao.variani, yan.rocha}@fatec.sp.gov.br

[**] Professor Orientador – Curso Superior de Tecnologia em Ciência de Dados – Faculdade de Tecnologia de Ourinhos – Fatec Ourinhos – vinicius.marques@fatecourinhos.edu.br

1 INTRODUÇÃO

A crescente utilização de sistemas digitais e serviços disponibilizados pela Internet tem ampliado a exposição de usuários e organizações a ameaças cibernéticas, entre as quais se destacam os ataques de *phishing*. Essa modalidade de fraude busca induzir usuários a fornecer informações sensíveis, como credenciais de autenticação e dados financeiros, frequentemente por meio de páginas fraudulentas que reproduzem características de serviços legítimos. A diversidade das estratégias empregadas pelos atacantes e a constante evolução dessas ameaças tornam necessária a investigação de mecanismos capazes de identificar websites maliciosos de maneira eficiente e confiável (SALAHDINE; MRABET; KAABOUCH, 2022; HANNOUSSE; YAHIOUCHE, 2021).

Nesse contexto, técnicas de aprendizado de máquina têm sido empregadas na identificação de padrões associados a websites fraudulentos, utilizando características extraídas de URLs, da estrutura das páginas e de propriedades dos domínios. Entretanto, a utilização de numerosos atributos não implica necessariamente melhor desempenho preditivo, uma vez que determinadas características podem apresentar baixa relevância, redundância ou relações pouco significativas com a variável-alvo. A presença dessas informações pode aumentar a complexidade do processo de aprendizagem e os custos computacionais envolvidos no treinamento dos modelos. Por outro lado, a remoção indiscriminada de atributos também pode eliminar informações discriminativas importantes, tornando necessário investigar estratégias capazes de equilibrar redução dimensional e preservação do desempenho de classificação (SAHOO; LIU; HOI, 2017; SHAHRIVARI; DARABI; IZADI, 2020).

A seleção de características (*feature selection*) constitui uma abordagem para investigar esse compromisso, permitindo identificar subconjuntos de atributos potencialmente relevantes para uma tarefa preditiva (GUYON; ELISSEEFF, 2003). Embora diferentes estratégias tenham sido desenvolvidas para essa finalidade, seus critérios de relevância podem produzir ordenações e subconjuntos distintos, especialmente quando aplicados a classificadores com diferentes mecanismos de aprendizagem. Nesse cenário, a avaliação de um método de seleção não deve se limitar à identificação de atributos associados à variável-alvo ou à obtenção de elevada acurácia, sendo necessário examinar também a consistência das seleções e os recursos computacionais empregados. Essa perspectiva é particularmente importante em aplicações de segurança da informação, nas quais a eficiência do processamento e a confiabilidade dos modelos constituem aspectos relevantes.

O *Combined Feature Importance Score* (CFIS), originalmente proposto por Marques (2024), apresenta uma estratégia de seleção de características baseada na integração de diferentes estimativas de importância em uma pontuação combinada. A proposta parte da possibilidade de que critérios distintos forneçam informações complementares sobre a relevância dos atributos, permitindo construir uma ordenação utilizada para selecionar subconjuntos de características. Entretanto, a combinação de medidas de importância não assegura, por si só, maior desempenho preditivo, estabilidade ou eficiência computacional. A identificação dessas propriedades depende de avaliações experimentais que considerem métodos concorrentes, diferentes

classificadores e procedimentos de validação capazes de examinar o comportamento dos subconjuntos selecionados.

Diante desse contexto, este trabalho investiga a seguinte questão de pesquisa: *em que medida o CFIS apresenta desempenho preditivo, estabilidade e eficiência computacional competitivos em relação a métodos consolidados de seleção de características na detecção de websites phishing?* Para respondê-la, realiza-se uma avaliação comparativa do CFIS em um conjunto de dados de detecção de *phishing*, considerando métodos de seleção fundamentados em diferentes critérios de relevância e três algoritmos de classificação supervisionada. A investigação contempla a preservação do desempenho preditivo após a redução dimensional, a estabilidade dos subconjuntos selecionados, a concordância entre métodos e os custos computacionais associados à seleção, utilizando validação cruzada e avaliação posterior em um conjunto de teste externo.

A principal contribuição deste trabalho consiste em apresentar uma avaliação experimental multidimensional do CFIS no contexto da detecção de websites *phishing*, examinando conjuntamente aspectos preditivos, estruturais e computacionais da seleção de características. Ao comparar os resultados obtidos com abordagens consolidadas e com a utilização integral dos atributos, o estudo busca identificar em quais condições o CFIS apresenta comportamento competitivo e quais limitações permanecem relevantes. Dessa forma, a investigação amplia as evidências empíricas disponíveis sobre o método, sem pressupor sua superioridade universal ou extrapolar os resultados para conjuntos de dados e cenários não avaliados.

2 FUNDAMENTAÇÃO TEÓRICA

Os métodos de seleção de características podem ser classificados em três categorias principais: *filter*, *wrapper* e *embedded*. As abordagens *filter* estimam a relevância dos atributos por meio de propriedades estatísticas dos dados, independentemente do desempenho de um classificador específico. Os métodos *wrapper* utilizam o desempenho de modelos preditivos para avaliar subconjuntos de características, enquanto as estratégias *embedded* incorporam mecanismos de seleção ao próprio processo de aprendizagem (KOHAVI; JOHN, 1997; GUYON; ELISSEEFF, 2003). Essas categorias diferem quanto às informações utilizadas para estimar a relevância dos atributos, ao custo computacional envolvido e à relação entre o procedimento de seleção e o algoritmo de classificação.

Entre as abordagens baseadas em propriedades estatísticas, a Informação Mútua (*Mutual Information*) quantifica a dependência entre uma característica e a variável-alvo, permitindo identificar associações que não se restringem necessariamente a relações lineares. Entretanto, sua aplicação individual aos atributos não considera diretamente a redundância existente entre as variáveis (PENG; LONG; DING, 2005). O *Correlation-based Feature Selection* (CFS), proposto por Hall (1999), utiliza um critério de avaliação de subconjuntos que favorece características associadas à variável-alvo e pouco redundantes entre si. Dessa maneira, enquanto a Informação Mútua pode ser empregada para ordenar características individualmente, o CFS considera também as relações existentes entre os atributos que compõem o

subconjunto.

O ReliefF pertence à família de métodos baseados em vizinhanças, cuja fundamentação está relacionada ao algoritmo Relief, originalmente apresentado por Kira e Rendell (1992). Essa abordagem estima a importância das características a partir de diferenças observadas entre instâncias próximas, considerando a capacidade dos atributos de distinguir observações pertencentes a classes distintas. Sua estratégia de avaliação difere daquela empregada por métodos fundamentados exclusivamente em medidas globais de associação estatística, pois explora propriedades locais da distribuição dos dados.

Entre os métodos incorporados ao processo de aprendizagem, a regularização L1 introduz uma penalização proporcional à soma dos valores absolutos dos coeficientes de um modelo. Essa penalização pode produzir soluções esparsas, nas quais determinados coeficientes assumem valor zero, permitindo identificar características com maior contribuição para o modelo ajustado. A fundamentação dessa estratégia está associada ao método LASSO, apresentado por Tibshirani (1996). Em aplicações de seleção de características, a magnitude dos coeficientes pode ser utilizada para estabelecer uma ordenação de relevância, desde que sejam consideradas as propriedades do modelo e a escala dos atributos.

Outras estratégias estimam a relevância das características a partir do comportamento de modelos preditivos previamente ajustados. A importância por permutação (*Permutation Feature Importance* – PFI) quantifica a alteração em uma métrica de desempenho após a permutação dos valores de determinado atributo, preservando os demais. O procedimento busca estimar a contribuição da característica para o desempenho do modelo, embora seus resultados possam ser influenciados por dependências entre variáveis e pela métrica de avaliação escolhida. Por sua vez, o método *SHapley Additive exPlanations* (SHAP), apresentado por Lundberg e Lee (2017), utiliza conceitos da teoria dos jogos cooperativos para atribuir contribuições às características nas predições. Para modelos baseados em árvores, o TreeSHAP oferece um procedimento especializado para o cálculo dessas contribuições, cujas magnitudes podem ser agregadas para produzir rankings globais de importância.

Além dos métodos orientados por critérios de relevância, a seleção aleatória de subconjuntos constitui uma referência experimental útil para examinar o benefício da utilização de mecanismos informados de seleção. Na estratégia *Random Top-K*, são escolhidos aleatoriamente K atributos, sem considerar sua associação com a variável-alvo ou sua contribuição para o desempenho de um classificador. A comparação com essa abordagem permite contextualizar os resultados obtidos pelos métodos de seleção, distinguindo os efeitos da simples redução dimensional daqueles associados à utilização de critérios específicos de relevância.

2.1 Critérios de Avaliação de Métodos de Seleção

A avaliação de um método de seleção de características envolve dimensões distintas, que não devem ser interpretadas como medidas equivalentes. O desempenho preditivo examina a capacidade dos subconjuntos selecionados de preservar informações úteis à classificação, enquanto a estabilidade investiga a consistência das

características identificadas quando o procedimento é aplicado a diferentes amostras de treinamento. A concordância entre métodos, por sua vez, representa a semelhança entre os subconjuntos produzidos por estratégias distintas, independentemente de apresentarem resultados preditivos próximos.

Uma medida frequentemente empregada para avaliar a sobreposição entre subconjuntos é o índice de Jaccard, definido pela razão entre o número de características presentes na interseção e o número de características presentes na união dos conjuntos comparados. Quando aplicado aos subconjuntos produzidos por diferentes métodos, esse índice permite examinar a concordância entre seletores; quando utilizado para comparar seleções obtidas por um mesmo método em diferentes amostras, fornece uma medida de consistência das escolhas realizadas. Entretanto, a sobreposição esperada pode variar conforme a quantidade de atributos selecionados, exigindo cautela na comparação de subconjuntos com diferentes dimensionalidades.

O índice de estabilidade de Nogueira, proposto por Nogueira, Sechidis e Brown (2018), constitui uma alternativa para avaliar a consistência dos procedimentos de seleção, considerando a variabilidade das escolhas e uma correção relacionada à concordância esperada ao acaso. Essa medida permite complementar indicadores de sobreposição direta, especialmente quando se pretende distinguir a estabilidade efetivamente observada daquela decorrente da quantidade de características selecionadas.

A eficiência computacional representa outra dimensão relevante, uma vez que os métodos podem apresentar diferenças expressivas no processamento necessário para estimar a importância dos atributos. Procedimentos que exigem treinamento de modelos auxiliares, múltiplas permutações ou cálculos de contribuições individuais podem apresentar custos superiores aos de abordagens estatísticas mais simples. Assim, a análise de eficiência deve considerar a etapa efetivamente mensurada, distinguindo o custo de seleção de características dos tempos de treinamento e inferência dos classificadores.

Para a comparação de resultados preditivos entre múltiplos métodos, podem ser empregados procedimentos estatísticos não paramétricos. O teste de Friedman permite investigar diferenças globais entre abordagens avaliadas em condições pareadas, enquanto o teste de Wilcoxon pode ser utilizado em contrastes entre pares de métodos. Quando são realizadas múltiplas comparações, o procedimento de Holm permite controlar a probabilidade de rejeições indevidas associadas à multiplicidade dos testes (DEMŠAR, 2006; WILCOXON, 1945; HOLM, 1979). A interpretação desses procedimentos depende das características do desenho experimental, incluindo o número de observações pareadas e a dependência existente entre elas.

2.2 O Método *Combined Feature Importance Score* (CFIS)

O *Combined Feature Importance Score* (CFIS), originalmente apresentado por Marques (2024), é um método de seleção de características fundamentado na integração de três medidas de relevância: a importância por permutação, a magnitude dos coeficientes de regressão logística e a correlação de Pearson entre cada atributo e a variável-alvo. A combinação desses componentes busca representar

diferentes aspectos da importância das características em uma pontuação única. A importância por permutação considera a contribuição de um atributo para o desempenho de um modelo auxiliar, os coeficientes da regressão logística representam sua participação em uma função de decisão linear e a correlação de Pearson quantifica a intensidade da associação linear com a variável-alvo. Após a normalização dos componentes, o método produz um ranking de relevância utilizado para determinar quais características serão preservadas no subconjunto selecionado.Marques (2025)

2.2.1 Formulação Matemática do CFIS

Considere uma matriz de características $X \in \mathbb{R}^{n \times d}$, em que n representa o número de observações e d corresponde à quantidade de atributos, e um vetor de rótulos binários $y \in \{0,1\}^n$. Para cada característica x_j, com $j \in \{1,\ldots,d\}$, o CFIS calcula três componentes de importância que são posteriormente normalizados e combinados.

O primeiro componente corresponde à importância por permutação, definida pela diferença média entre a acurácia original de um modelo auxiliar f e a acurácia obtida após a permutação dos valores do atributo j:

$$\text{ImpPerm}_j = \frac{1}{R} \sum_{r=1}^{R} \left[A(f, X, y) - A(f, \pi_{j,r}(X), y) \right], \tag{1}$$

em que A representa a acurácia de classificação, R corresponde ao número de repetições e $\pi_{j,r}(X)$ representa a matriz de características após a permutação da coluna j na repetição r. Valores negativos de importância indicam que a permutação não produziu a redução de desempenho esperada e, na implementação considerada, não contribuem positivamente para o escore combinado.

O segundo componente é obtido a partir do valor absoluto do coeficiente w_j associado ao atributo x_j em um modelo de regressão logística. A utilização da magnitude permite considerar a intensidade da contribuição estimada pelo modelo, independentemente do sinal do coeficiente. O terceiro componente corresponde ao valor absoluto da correlação de Pearson entre o atributo e a variável-alvo, cuja formulação é expressa por:

$$\rho_{x_j,y} = \frac{\sum_{i=1}^{n} (x_{ij} - \bar{x}_j)(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n} (x_{ij} - \bar{x}_j)^2} \sqrt{\sum_{i=1}^{n} (y_i - \bar{y})^2}}. \tag{2}$$

Na implementação avaliada, correlações com denominadores numericamente nulos recebem valor zero. Como os três componentes apresentam escalas distintas, seus valores são submetidos a uma normalização que considera contribuições não negativas e a soma das magnitudes de cada componente. Para um vetor de relevâncias a, essa transformação é definida por:

$$\mathcal{N}(a_j) = \begin{cases} \dfrac{\max(0, a_j)}{\sum_{\ell=1}^{d} \max(0, a_\ell)}, & \text{se } \sum_{\ell=1}^{d} \max(0, a_\ell) > 10^{-12}, \\ 0, & \text{caso contrário.} \end{cases} \tag{3}$$

Antes da normalização, valores não finitos são convertidos em zero, evitando sua propagação para a pontuação final. A operação também impede que importâncias negativas por permutação produzam contribuições negativas no escore combinado. Após essa etapa, os três componentes normalizados recebem pesos iguais, resultando na formulação do CFIS:

$$\boxed{\text{CFIS}_j = \frac{\widehat{\text{ImpPerm}}_j + \widehat{|w_j|} + \widehat{|\rho_{x_j,y}|}}{3}} \tag{4}$$

em que os termos com acento circunflexo representam os respectivos componentes após a aplicação da normalização definida na Equação 3. A atribuição de pesos iguais estabelece uma contribuição nominal de um terço para cada medida, sem introduzir parâmetros adicionais de ponderação. Os atributos são ordenados de maneira decrescente conforme a pontuação obtida, e os K primeiros elementos do ranking constituem o subconjunto selecionado. Dessa forma, o CFIS fornece um critério combinado de ordenação das características, cuja qualidade preditiva, estabilidade e eficiência devem ser verificadas empiricamente.

3 METODOLOGIA EXPERIMENTAL

A metodologia experimental foi estruturada para avaliar comparativamente o comportamento do *Combined Feature Importance Score* (CFIS) em relação a métodos consolidados de seleção de características, considerando desempenho preditivo, redução dimensional, estabilidade dos subconjuntos selecionados e eficiência computacional. Para assegurar a consistência das comparações, os métodos foram submetidos a um protocolo comum de pré-processamento, validação e avaliação, utilizando os mesmos dados e classificadores. A Figura 1 apresenta o fluxo geral da metodologia, desde a preparação do conjunto de dados até a análise comparativa dos resultados.

3.1 Conjunto de Dados

Os experimentos utilizaram o *Web Page Phishing Detection Dataset*, apresentado por Hannousse e Yahiouche (2021), composto por 11.430 observações e 87 atributos preditores. O conjunto contempla duas classes balanceadas, correspondentes a websites legítimos e páginas associadas a ataques de *phishing*. As características disponíveis representam diferentes propriedades relacionadas às URLs, à estrutura das páginas web e a indicadores associados aos websites. Essa diversidade permite investigar o comportamento dos métodos de seleção diante de atributos que podem apresentar diferentes níveis de relevância e redundância. Inicialmente, o conjunto de dados foi dividido de maneira estratificada, preservando a distribuição das classes.

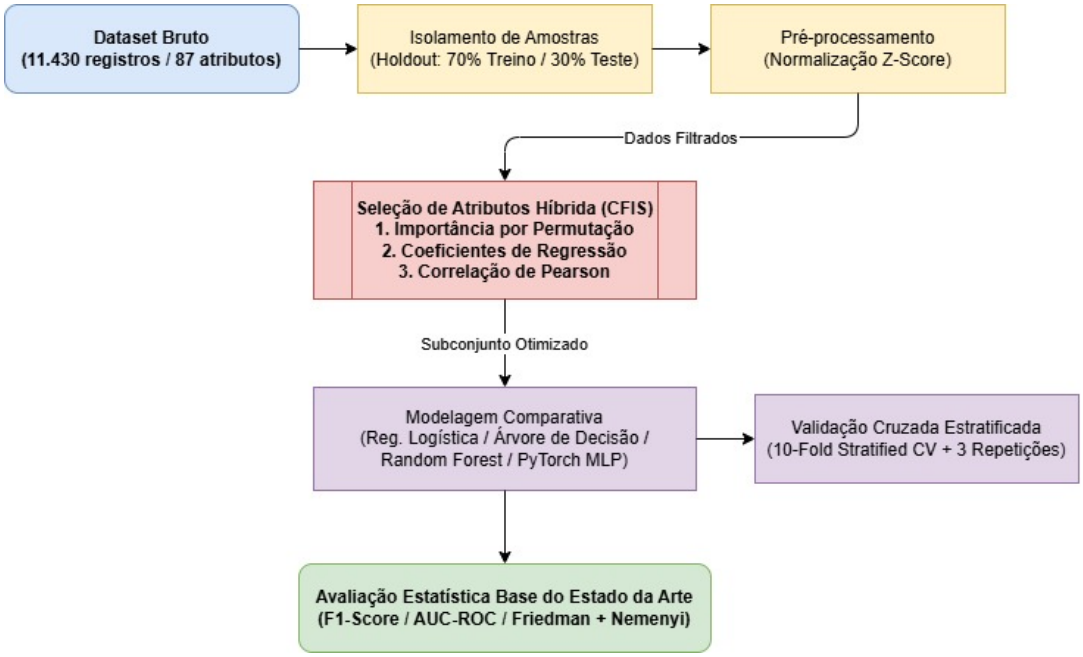


Figura 1 – Fluxo metodológico da avaliação comparativa dos métodos de seleção de características.

Fonte: elaborado pelos autores.

Foram destinados 70% dos registros ao conjunto de desenvolvimento, totalizando 8.001 observações, e os 30% restantes ao conjunto de teste externo, correspondentes a 3.429 observações. A divisão utilizou a semente aleatória 42, visando à reprodutibilidade dos experimentos. O conjunto de teste externo permaneceu isolado durante as etapas de desenvolvimento, seleção de características e validação cruzada. Sua utilização ocorreu somente na avaliação final dos modelos, permitindo examinar o desempenho preditivo em observações não utilizadas nas etapas anteriores.

3.2 Ambiente Computacional

A implementação e a execução dos experimentos foram realizadas no ambiente Google Colaboratory (*Google Colab*), utilizando a linguagem de programação Python e bibliotecas de aprendizado de máquina e análise de dados. O ambiente foi empregado para organizar o processamento dos dados, executar os métodos de seleção de características, treinar os classificadores e registrar as métricas experimentais. Entre as bibliotecas utilizadas, destaca-se o *Scikit-learn*, que disponibiliza implementações de algoritmos de classificação, procedimentos de pré-processamento, validação cruzada e métricas de avaliação (PEDREGOSA et al., 2011). A execução em um ambiente de notebooks permitiu organizar as diferentes etapas do protocolo experimental e armazenar os resultados obtidos para posterior comparação. Os procedimentos foram desenvolvidos de modo a utilizar configurações controladas e sementes aleatórias definidas nas etapas aplicáveis.

3.3 Pré-processamento dos Dados

O pré-processamento foi realizado separadamente em cada partição de treinamento, evitando o compartilhamento de informações entre os conjuntos utilizados para ajuste e avaliação dos modelos. Inicialmente, os valores ausentes foram tratados por imputação utilizando a mediana dos respectivos atributos, calculada exclusivamente a partir das observações disponíveis no conjunto de treinamento. Em seguida, foi aplicada a padronização Z-score, que transforma os valores das características considerando a média e o desvio padrão estimados no treinamento. A transformação é expressa por:

$$z_{ij} = \frac{x_{ij} - \mu_j^{(\text{treino})}}{\sigma_j^{(\text{treino})}}, \tag{5}$$

em que x_{ij} representa o valor original do atributo j para a observação i, $\mu_j^{(\text{treino})}$ corresponde à média do atributo no conjunto de treinamento e $\sigma_j^{(\text{treino})}$ representa seu desvio padrão.

Os parâmetros de imputação e padronização estimados durante o treinamento foram posteriormente aplicados aos dados de validação, sem novo ajuste. Esse procedimento foi repetido em cada partição da validação cruzada e, posteriormente, na avaliação final, utilizando o conjunto completo de desenvolvimento para estimar os parâmetros aplicados ao teste externo. A aplicação dessas transformações buscou assegurar condições consistentes para os métodos de seleção e classificadores, especialmente aqueles sensíveis à escala das características.

3.4 Protocolo de Validação Experimental

A avaliação foi conduzida por meio de validação cruzada estratificada com cinco partições (*Stratified 5-Fold Cross-Validation*), aplicada exclusivamente ao conjunto de desenvolvimento. Nesse procedimento, os 8.001 registros foram distribuídos em cinco subconjuntos com proporções de classes preservadas. Em cada iteração, quatro subconjuntos foram utilizados para treinamento e um para validação, alternando-se o subconjunto reservado à avaliação até que todas as partições fossem utilizadas. Em cada iteração, o pré-processamento, a seleção de características e o treinamento dos classificadores foram realizados utilizando exclusivamente os dados de treinamento da partição. Posteriormente, os modelos foram avaliados nos dados de validação correspondentes.

Essa organização buscou evitar vazamento de informações (*data leakage*), especialmente durante a seleção de características, uma vez que a utilização de informações do conjunto de validação poderia produzir estimativas excessivamente otimistas do desempenho preditivo. Após a conclusão da validação cruzada, os métodos foram novamente ajustados sobre o conjunto completo de desenvolvimento. Os classificadores resultantes foram então avaliados uma única vez no conjunto de teste externo, preservando a independência dessa etapa em relação à seleção das características.

3.5 Métodos de Seleção e Classificadores

Foram avaliados oito métodos de seleção de características: CFIS, regularização L1, Informação Mútua, *Correlation-based Feature Selection* (CFS), ReliefF, TreeSHAP, importância por permutação (PFI) e seleção aleatória *Random Top-K*. Adicionalmente, foi considerada uma configuração de referência denominada *All Features*, na qual todos os 87 atributos disponíveis foram utilizados no treinamento, sem aplicação de seleção.A inclusão dessa configuração permitiu verificar em que medida a redução dimensional preservou ou modificou o desempenho dos classificadores em relação à utilização integral das características. Os métodos foram avaliados com três algoritmos de classificação supervisionada:

- **Árvore de Decisão (*Decision Tree*):** classificador que organiza regras de decisão em uma estrutura hierárquica, permitindo representar relações não lineares entre os atributos;
- **Regressão Logística (*Logistic Regression*):** modelo linear probabilístico utilizado em problemas de classificação binária;
- **Random Forest:** método de aprendizado em conjunto baseado na combinação de múltiplas árvores de decisão, configurado neste estudo com 100 estimadores.

A quantidade de características selecionadas foi definida de acordo com o classificador avaliado, sendo estabelecidos $K = 15$ atributos para Árvore de Decisão, $K = 60$ para Regressão Logística e $K = 45$ para Random Forest. Esses valores foram mantidos para todos os métodos de seleção dentro de cada classificador, assegurando que as comparações fossem realizadas com subconjuntos de mesma dimensionalidade. A configuração *All Features* utilizou os 87 atributos originais. Considerando os oito métodos de seleção e a configuração de referência, foram avaliadas nove abordagens em três classificadores e cinco partições de validação cruzada, totalizando:

$$N_{\mathrm{CV}} = 9 \times 3 \times 5 = 135. \tag{6}$$

Após a validação cruzada, foram realizadas 27 avaliações finais no conjunto de teste externo, correspondentes às nove abordagens combinadas com os três classificadores.

3.6 Métricas de Avaliação

A avaliação dos métodos considerou diferentes dimensões, incluindo desempenho preditivo, redução dimensional, estabilidade, concordância entre seletores e eficiência computacional.

O desempenho preditivo foi analisado principalmente por meio da métrica F1-macro, que calcula a média aritmética dos valores de F1 obtidos para cada classe. Sua formulação é apresentada na Equação 7:

$$F_{1,\text{macro}} = \frac{1}{C} \sum_{c=1}^{C} \frac{2P_c R_c}{P_c + R_c}, \tag{7}$$

em que C corresponde ao número de classes, P_c representa a precisão da classe c e R_c corresponde à sua revocação.

Também foram consideradas a acurácia balanceada (*Balanced Accuracy*), a área sob a curva ROC (*AUC-ROC*) e o coeficiente de correlação de Matthews (*Matthews Correlation Coefficient* – MCC), permitindo complementar a análise do comportamento dos classificadores. A acurácia balanceada corresponde à média das taxas de acerto por classe, sendo expressa, no caso binário, por:

$$\text{BA} = \frac{\text{TPR} + \text{TNR}}{2}, \tag{8}$$

em que TPR representa a taxa de verdadeiros positivos e TNR corresponde à taxa de verdadeiros negativos. A redução dimensional foi mensurada pela proporção de atributos removidos em relação ao conjunto original:

$$\text{Reduão}(\%) = \left(1 - \frac{K}{d}\right) \times 100, \tag{9}$$

em que K corresponde ao número de características selecionadas e d representa a quantidade original de atributos.

3.7 Estabilidade e Concordância dos Subconjuntos

A estabilidade dos métodos foi investigada considerando a consistência dos subconjuntos de características selecionados nas diferentes partições da validação cruzada. Para essa análise, foi utilizado o índice de Jaccard, que quantifica a proporção de características compartilhadas entre dois subconjuntos em relação à união dos elementos selecionados:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}, \tag{10}$$

em que A e B representam dois subconjuntos de características.

A estabilidade entre partições foi estimada pela média dos índices de Jaccard calculados entre os pares de subconjuntos obtidos ao longo da validação cruzada. Adicionalmente, foi empregado o índice de estabilidade de Nogueira, que considera a variabilidade das seleções e incorpora uma correção relacionada à concordância esperada ao acaso (NOGUEIRA; SECHIDIS; BROWN, 2018). A concordância entre métodos foi investigada pela sobreposição dos subconjuntos selecionados, permitindo comparar as características priorizadas pelo CFIS com aquelas identificadas por abordagens como TreeSHAP e PFI. É importante distinguir essas duas dimensões: a estabilidade representa a consistência de um mesmo método diante de diferentes

amostras, enquanto a concordância descreve a semelhança entre os resultados de métodos distintos.

3.8 Eficiência Computacional e Análise Estatística

A eficiência computacional foi analisada por meio do tempo necessário à execução dos procedimentos de seleção de características. Os tempos foram registrados durante a validação cruzada e utilizados para comparar o custo computacional dos métodos avaliados. Essa análise permitiu examinar as relações entre o desempenho preditivo obtido e o processamento necessário para identificar os subconjuntos de atributos. Para investigar a existência de diferenças estatísticas entre os métodos, foi empregado o teste não paramétrico de Friedman, aplicado aos resultados de F1-macro obtidos nas partições de validação cruzada (DEMŠAR, 2006). Adicionalmente, foram realizados contrastes pareados por meio do teste de Wilcoxon, com correção de Holm para múltiplas comparações (WILCOXON, 1945; HOLM, 1979).

Foi adotado nível de significância de 5% ($\alpha = 0,05$). Considerando a utilização de cinco partições de validação cruzada e a sobreposição entre os respectivos conjuntos de treinamento, os resultados dos testes foram interpretados com cautela, reconhecendo-se as limitações inferenciais desse protocolo. A análise conjunta das métricas buscou fornecer uma avaliação abrangente do CFIS, considerando não apenas sua capacidade de preservar o desempenho preditivo após a seleção de características, mas também a estabilidade dos subconjuntos obtidos e os custos computacionais associados ao procedimento.

4 RESULTADOS

4.1 Desempenho Preditivo na Validação Cruzada

Os resultados da validação cruzada estratificada, apresentados na Tabela 1, evidenciam diferenças no comportamento dos métodos de seleção de características em função do classificador empregado. Considerando as cinco partições de validação, o CFIS apresentou o maior F1-macro médio para Árvore de Decisão (0,9308) e Regressão Logística (0,9471), enquanto a utilização de todos os atributos obteve o melhor resultado para Random Forest (0,9631). Na Árvore de Decisão, o CFIS superou numericamente a configuração sem seleção, que registrou 0,9299, demonstrando que a utilização de 15 atributos foi suficiente para preservar o desempenho preditivo médio observado com as 87 características originais. Com Regressão Logística, o CFIS alcançou 0,9471, frente a 0,9455 obtido com todos os atributos, utilizando um subconjunto de 60 características. Para Random Forest, o CFIS apresentou F1-macro de 0,9619, próximo ao resultado de 0,9631 da configuração integral, com redução de 87 para 45 atributos. Esses resultados indicam que a seleção de características pode preservar níveis elevados de desempenho mesmo com reduções substanciais de dimensionalidade, embora os benefícios observados variem conforme a estrutura do classificador e o subconjunto selecionado.

A comparação com os demais métodos também evidencia que não houve

uma estratégia consistentemente superior em todas as configurações. Na Árvore de Decisão, o CFIS apresentou a maior média, seguido pela configuração com todos os atributos e pela regularização L1. Na Regressão Logística, o CFIS novamente obteve a maior média, enquanto L1 e All Features apresentaram resultados próximos. No Random Forest, as diferenças entre os métodos não aleatórios foram reduzidas, com valores de F1-macro concentrados em uma faixa estreita. Em contrapartida, o Random Top-K apresentou os menores resultados nos três classificadores, além de maior variabilidade entre as partições, especialmente na Árvore de Decisão. Esse comportamento sugere que a utilização de critérios de relevância contribuiu para a obtenção de subconjuntos mais informativos do que aqueles selecionados aleatoriamente no cenário investigado. Entretanto, as diferenças numéricas entre os métodos devem ser interpretadas em conjunto com a análise estatística, uma vez que a superioridade de uma média não implica necessariamente uma diferença estatisticamente significativa.

Tabela 1 – F1-macro médio na validação cruzada estratificada (cinco folds).

Método	Árvore de Decisão	Regressão Logística	Random Forest
All Features	0,9299 $\pm$ 0,0046	0,9455 $\pm$ 0,0023	**0,9631 $\pm$ 0,0033**
CFIS	**0,9308 $\pm$ 0,0061**	**0,9471 $\pm$ 0,0019**	0,9619 $\pm$ 0,0047
CFS	0,9259 $\pm$ 0,0096	0,9429 $\pm$ 0,0048	0,9610 $\pm$ 0,0039
L1	0,9295 $\pm$ 0,0051	0,9456 $\pm$ 0,0020	0,9615 $\pm$ 0,0044
Informação mútua	0,9165 $\pm$ 0,0072	0,9441 $\pm$ 0,0037	0,9610 $\pm$ 0,0057
PFI	0,9273 $\pm$ 0,0091	0,9418 $\pm$ 0,0014	0,9619 $\pm$ 0,0050
Random Top-K	0,8246 $\pm$ 0,0469	0,9313 $\pm$ 0,0116	0,9471 $\pm$ 0,0136
ReliefF	0,9199 $\pm$ 0,0054	0,9426 $\pm$ 0,0023	0,9623 $\pm$ 0,0019
TreeSHAP	0,9241 $\pm$ 0,0050	0,9430 $\pm$ 0,0014	0,9626 $\pm$ 0,0033

Fonte: elaborado pelos autores. Valores apresentados como média $\pm$ desvio padrão.

4.2 Generalização no Conjunto de Teste Externo

A avaliação no conjunto de teste externo, apresentada na Tabela 2, permite examinar o comportamento dos métodos em observações que permaneceram isoladas durante a validação cruzada e a seleção de características. Os resultados mostram que o CFIS manteve desempenho competitivo nos três classificadores, embora sua posição relativa tenha variado em relação às médias observadas na validação. Na Árvore de Decisão, o CFIS alcançou F1-macro de 0,9355, enquanto a configuração com todos os atributos obteve 0,9379, correspondendo a uma diferença absoluta de 0,0024. Essa diferença ocorreu apesar da utilização de apenas 15 das 87 características originais, representando redução dimensional de 82,76%. Na Regressão Logística, o CFIS apresentou o maior F1-macro entre todas as abordagens avaliadas, alcançando 0,9425, frente a 0,9396 da configuração integral, diferença absoluta favorável de 0,0029. Para Random Forest, o CFIS registrou 0,9630, enquanto PFI e All Features alcançaram 0,9650, diferença absoluta de 0,0020. Esses resultados demonstram que a redução dimensional promovida pelo CFIS foi acompanhada de pequenas variações no desempenho preditivo, incluindo ganho numérico na Regressão Logística e perdas discretas nos classificadores baseados em árvores.

A análise comparativa também evidencia que a preservação do desempenho não depende exclusivamente da quantidade de características selecionadas, mas da capacidade do método de identificar atributos relevantes para cada classificador. Na Árvore de Decisão, CFIS, CFS e L1 apresentaram o mesmo F1-macro de 0,9355, indicando desempenho equivalente na precisão reportada, apesar de utilizarem critérios distintos de seleção. Na Regressão Logística, CFIS, PFI e L1 apresentaram os maiores valores, enquanto Random Top-*K* registrou o menor resultado. No Random Forest, PFI e All Features compartilharam o maior F1-macro, seguidos por CFIS e outros métodos com diferenças relativamente pequenas. Assim, os resultados externos reforçam a competitividade do CFIS, mas não sustentam a conclusão de que sua utilização proporciona ganhos sistemáticos de desempenho em todos os classificadores.

Tabela 2 – F1-macro no holdout externo (3.429 observações).

Método	Árvore de Decisão	Regressão Logística	Random Forest
All Features	**0,9379**	0,9396	**0,9650**
CFIS	0,9355	**0,9425**	0,9630
CFS	0,9355	0,9373	0,9627
L1	0,9355	0,9405	0,9612
Informação mútua	0,9309	0,9402	0,9621
PFI	0,9326	0,9411	**0,9650**
Random Top-*K*	0,8309	0,9227	0,9536
ReliefF	0,9204	0,9396	0,9618
TreeSHAP	0,9329	0,9399	0,9621

Fonte: elaborado pelos autores.

As métricas complementares apresentadas na Tabela 3 permitem ampliar a análise do CFIS para além do F1-macro. A Árvore de Decisão apresentou acurácia balanceada de 0,9356, AUC-ROC de 0,9356 e MCC de 0,8711, utilizando apenas 15 características. Na Regressão Logística, os valores de acurácia balanceada, AUC-ROC e MCC foram, respectivamente, 0,9425, 0,9842 e 0,8851, com 60 atributos selecionados. O Random Forest apresentou os maiores valores dessas três métricas entre os classificadores avaliados com CFIS, alcançando acurácia balanceada de 0,9630, AUC-ROC de 0,9927 e MCC de 0,9260, com 45 características. Os resultados indicam que os subconjuntos selecionados pelo CFIS permitiram manter capacidade discriminativa elevada nos três modelos, embora a comparação entre classificadores deva considerar suas diferentes estruturas e os respectivos tamanhos dos subconjuntos utilizados.

4.3 Eficiência Computacional

A eficiência computacional dos métodos foi investigada a partir dos tempos médios de seleção registrados durante a validação cruzada, conforme apresentado na Tabela 4. O CFIS apresentou tempos de 0,7446 s, 0,6339 s e 0,6324 s para Árvore de Decisão, Regressão Logística e Random Forest, respectivamente. Em comparação, TreeSHAP registrou tempos entre 19,5537 s e 19,8467 s, enquanto PFI apresentou

Tabela 3 – Métricas complementares do CFIS no holdout externo.

Classificador	K	Redução	BA	AUC-ROC	MCC
Árvore de Decisão	15	82,76%	0,9356	0,9356	0,8711
Regressão Logística	60	31,03%	0,9425	0,9842	0,8851
Random Forest	45	48,28%	0,9630	0,9927	0,9260

Fonte: elaborado pelos autores. BA: acurácia balanceada; MCC: coeficiente de Matthews.

valores entre 30,7506 s e 33,1850 s, e ReliefF demandou aproximadamente 64 a 65 segundos. Essa diferença evidencia que, no ambiente e nas configurações experimentais utilizados, o CFIS apresentou menor custo de seleção do que esses três métodos, preservando desempenho preditivo competitivo. A magnitude das diferenças também indica que o custo computacional pode representar um fator relevante na escolha do seletor, especialmente em aplicações que exigem repetição do procedimento em diferentes partições, conjuntos de treinamento ou ciclos de atualização dos modelos.

Entretanto, a vantagem computacional do CFIS não foi observada em relação a todas as abordagens avaliadas. Os métodos CFS e L1 apresentaram tempos inferiores a 0,15 s nos três classificadores, enquanto Random Top-K apresentou custo praticamente desprezível, por não realizar estimativas de relevância. A Informação Mútua também apresentou tempos superiores aos do CFIS, mas consideravelmente inferiores aos registrados por TreeSHAP, PFI e ReliefF. Esses resultados demonstram a existência de diferentes compromissos entre custo computacional e qualidade preditiva, reforçando a importância de considerar ambas as dimensões na avaliação dos métodos. Ressalta-se que os tempos apresentados correspondem à etapa de seleção de características, não constituindo uma medida direta do tempo de treinamento completo ou da latência de inferência dos classificadores.

Tabela 4 – Tempo médio de seleção de atributos na validação cruzada (segundos).

Método	Árvore de Decisão	Regressão Logística	Random Forest
CFIS	0,7446	0,6339	0,6324
CFS	0,1344	0,1210	0,0704
L1	0,1415	0,1082	0,0905
Informação mútua	2,3379	1,8764	1,7000
PFI	30,7506	30,9483	33,1850
Random Top-K	0,0003	0,0002	0,0003
ReliefF	65,3576	63,8458	65,2226
TreeSHAP	19,8431	19,8467	19,5537

Fonte: elaborado pelos autores. All Features não executa seleção e foi omitido.

4.4 Estabilidade e Concordância dos Subconjuntos

A estabilidade dos subconjuntos selecionados constitui uma dimensão complementar à avaliação preditiva, pois permite examinar a consistência das características

identificadas quando o método é aplicado a diferentes partições de treinamento. Conforme apresentado na Tabela 5, o CFIS registrou valores do índice de Nogueira de 0,8631, 0,8980 e 0,8941 para Árvore de Decisão, Regressão Logística e Random Forest, respectivamente. O índice de Jaccard médio entre partições apresentou valores de 0,7978, 0,9389 e 0,9034, indicando elevada sobreposição dos subconjuntos selecionados nas cinco partições. O maior valor de Jaccard foi observado na Regressão Logística, com 60 características, enquanto a Árvore de Decisão apresentou a menor sobreposição, utilizando apenas 15 atributos. Esse comportamento deve ser interpretado considerando a influência do tamanho dos subconjuntos sobre a sobreposição esperada, uma vez que seleções com diferentes valores de K não são diretamente equivalentes.

A análise de concordância entre métodos revelou diferenças relevantes nas características priorizadas pelo CFIS em comparação com TreeSHAP e PFI. Para Árvore de Decisão, os índices de Jaccard foram de 0,3529 em relação ao TreeSHAP e 0,2866 em relação ao PFI, indicando sobreposição relativamente limitada entre os subconjuntos selecionados. Na Regressão Logística, esses valores aumentaram para 0,7649 e 0,5867, respectivamente, enquanto no Random Forest foram registrados 0,6669 e 0,5254. Em todas as configurações, a concordância entre CFIS e TreeSHAP foi superior à observada entre CFIS e PFI. Esses resultados demonstram que os métodos podem identificar subconjuntos distintos mesmo quando apresentam desempenho preditivo semelhante, evidenciando a influência dos diferentes critérios de importância sobre a ordenação das características. Entretanto, a divergência entre subconjuntos não permite concluir, isoladamente, que um método identifique características mais relevantes do que outro.

Tabela 5 – Estabilidade do CFIS e concordância com seletores de referência.

Classificador	K	Nogueira	Jaccard entre folds	CFIS–TreeSHAP	CFIS–PFI
Árvore de Decisão	15	0,8631	0,7978	0,3529	0,2866
Regressão Logística	60	0,8980	0,9389	0,7649	0,5867
Random Forest	45	0,8941	0,9034	0,6669	0,5254

Fonte: elaborado pelos autores. Concordância medida por Jaccard@K.

4.5 Análise Estatística dos Resultados

A análise estatística foi conduzida para investigar se as diferenças observadas no desempenho preditivo dos métodos poderiam ser consideradas significativas sob o protocolo experimental adotado. O teste de Friedman, aplicado aos valores de F1-macro obtidos nas cinco partições de validação cruzada, identificou diferenças globais entre os nove métodos para Árvore de Decisão ($\chi^2_F = 26,4000$; $p = 0,000897$) e Regressão Logística ($\chi^2_F = 26,4615$; $p = 0,000875$). Para Random Forest, o resultado não atingiu o nível de significância estabelecido ($\chi^2_F = 14,7960$; $p = 0,063236$). Esses resultados indicam evidência de diferenças globais entre as abordagens nos dois primeiros classificadores, mas não permitem identificar diretamente quais pares de métodos diferem entre si.

Para investigar especificamente o comportamento do CFIS em relação aos métodos concorrentes, foram realizados contrastes pareados utilizando o teste de Wilcoxon, com ajuste de Holm para múltiplas comparações. Os resultados não identificaram diferenças estatisticamente significativas entre o CFIS e os demais métodos ao nível de significância de 5%. Dessa forma, embora o CFIS tenha apresentado as maiores médias de F1-macro na validação cruzada para Árvore de Decisão e Regressão Logística, essas vantagens numéricas não podem ser interpretadas como demonstração de superioridade estatística. Além disso, a utilização de apenas cinco partições, com sobreposição entre os conjuntos de treinamento, limita a independência das observações e a capacidade inferencial dos testes. Consequentemente, os resultados estatísticos devem ser compreendidos como evidências exploratórias referentes ao conjunto de dados e ao protocolo investigados, não como comprovação de superioridade generalizável para diferentes problemas de classificação.

5 DISCUSSÃO

Os resultados revelam que o CFIS seleciona subconjuntos preditivamente competitivos, com ganhos modestos em algumas configurações e perdas modestas em outras. O resultado de Regressão Logística no holdout sugere utilidade da combinação de critérios de importância, mas não demonstra que o método seja superior em qualquer base de dados. Para Árvore de Decisão, a redução de 87 para 15 atributos preservou desempenho próximo ao baseline; para Random Forest, o uso de todos os atributos e PFI resultou em F1-macro ligeiramente maior.

A vantagem de custo do CFIS sobre TreeSHAP, PFI e ReliefF é relevante para pipelines que executam seleção repetidamente. Entretanto, não se deve generalizar essa vantagem a todos os seletores: L1 e CFS foram mais rápidos. O CFIS também apresentou estabilidade elevada entre folds, embora o desenho de cinco partições com sobreposição entre conjuntos de treinamento não equivalha a repetições independentes. Além disso, a concordância limitada com TreeSHAP e PFI indica critérios de priorização distintos, mas não constitui evidência suficiente de descoberta de atributos intrinsecamente superiores.

As principais limitações são o uso de um único conjunto de dados, a quantidade restrita de partições para inferência estatística, o fato de K variar entre classificadores e a ausência de uma avaliação externa em domínios distintos. Não foram realizados os experimentos com MLP, dez folds e três repetições descritos como planejamento na qualificação; tais procedimentos não integram as conclusões deste artigo. O estudo não reivindica generalização para regressão, classificação multiclasse ou cenários de produção sem experimentação adicional.

6 CONCLUSÃO

Este estudo apresentou uma avaliação experimental do CFIS para seleção de atributos em detecção de websites phishing. O método combinou importância por permutação, magnitude de coeficientes de regressão logística e correlação de Pearson, com normalização e ponderação igualitária dos componentes. Em 135 avali-

ações de validação cruzada e 27 avaliações de holdout, o CFIS manteve desempenho competitivo com subconjuntos menores de atributos. No holdout externo, destacou-se em Regressão Logística, alcançando F1-macro de 0,9425 com 60 atributos, frente a 0,9396 com todos os 87 atributos. A estabilidade entre partições foi elevada, e o custo de seleção foi inferior ao de TreeSHAP, PFI e ReliefF. Os testes estatísticos, contudo, não demonstraram superioridade significativa do CFIS nos contrastes pareados ajustados. Trabalhos futuros devem investigar sua robustez em múltiplos conjuntos de dados, diferentes tamanhos de amostra e problemas de classificação com características estatísticas distintas.

7 REFERÊNCIAS

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006. Citado 2 vezes nas páginas 5 e 12.

GUYON, I.; ELISSEEFF, A. An introduction to variable and feature selection. *Journal of Machine Learning Research*, v. 3, p. 1157–1182, 2003. Citado 2 vezes nas páginas 2 e 3.

HALL, M. A. Correlation-based feature selection for machine learning. *PhD Thesis – University of Waikato*, Hamilton, New Zealand, 1999. Citado na página 3.

HANNOUSSE, A.; YAHIOUCHE, S. Towards benchmark datasets for phishing websites detection. *Applied Soft Computing*, Elsevier, v. 108, p. 107471, 2021. Citado 2 vezes nas páginas 2 e 7.

HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979. Citado 2 vezes nas páginas 5 e 12.

KIRA, K.; RENDELL, L. A. The feature selection problem: Traditional methods and a new algorithm. In: *Proceedings of the Tenth National Conference on Artificial Intelligence (AAAI-92)*. [S.l.]: AAAI Press, 1992. p. 129–134. Citado na página 4.

KOHAVI, R.; JOHN, G. H. Wrappers for feature subset selection. *Artificial Intelligence*, Elsevier, v. 97, n. 1–2, p. 273–324, 1997. Citado na página 3.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS 2017)*, v. 30, p. 4765–4774, 2017. Citado na página 4.

MARQUES, V. G. A métrica cfis: Uma nova perspectiva na análise da importância das features em modelos de machine learning. *Revista e-Fatec*, v. 14, n. 2, oct 2024. Disponível em: <https://pesquisafatec.com.br/ojs/efatec/pt_BR/article/view/339>. Citado 2 vezes nas páginas 2 e 5.

MARQUES, V. G. Avaliação comparativa da métrica CFIS frente a métodos do estado da arte em seleção de features. *Institute of Geosciences and Exact Sciences – São Paulo State University (UNESP)*, Rio Claro, SP, Brazil, 2025. Citado na página 6.

NOGUEIRA, S.; SECHIDIS, K.; BROWN, G. On the stability of feature selection algorithms. *Journal of Machine Learning Research*, v. 18, n. 174, p. 1–54, 2018. Citado 2 vezes nas páginas 5 e 11.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Citado na página 8.

PENG, H.; LONG, F.; DING, C. Feature selection based on mutual information: Criteria of max-dependency, max-relevance, and min-redundancy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, IEEE, v. 27, n. 8, p. 1226–1238, 2005. Citado na página 3.

SAHOO, D.; LIU, C.; HOI, S. C. H. Malicious url detection using machine learning: A survey. *arXiv preprint arXiv:1701.07179*, 2017. Citado na página 2.

SALAHDINE, F.; MRABET, N. E.; KAABOUCH, N. Phishing attacks: detection and mitigation techniques. *Journal of Cybersecurity and Privacy*, MDPI, v. 2, n. 1, p. 107–124, 2022. Citado na página 2.

SHAHRIVARI, V.; DARABI, M. M.; IZADI, M. Phishing detection using machine learning techniques. *arXiv preprint arXiv:2010.12847*, 2020. Citado na página 2.

TIBSHIRANI, R. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, Wiley Online Library, v. 58, n. 1, p. 267–288, 1996. Citado na página 4.

WILCOXON, F. Individual comparisons by ranking methods. *Biometrics Bulletin*, v. 1, n. 6, p. 80–83, 1945. Citado 2 vezes nas páginas 5 e 12.